Practica 2

Introducción a la Ciencia de Datos. Máster en Ciencia de Datos- UV

Pau Bover Femenias

2026-10-26

Índice

1. Practica 2 **1**
1.1. Ejercicio 1 1
1.2. Ejercicio 2 6
1.3. Ejercicio 3 10
1.4. Ejercicio 4 15
1.5. Ejercicio 6 22
1.6. Ejercicio 7 25
1.7. Ejercicio 8 29

1. Practica 2

Pau Bover Femenias

```
library(pacman)
packages =  c("tidyverse", "knitr", "ggplot2", "datasets", "RColorBrewer",'latex2exp')
pacman::p_load(char=packages)
```

Cargamos las bibliotecas que usaremos durante la practica y creamos la carpeta de results.

```
# Creamos la carpeta de resultados si no existe.
dir.create("results", showWarnings = FALSE)
```

1.1. Ejercicio 1

Cargamos el fichero con formato .RData de la carpeta de data.

```
# Cargamos el fichero, que contiene el conjunto de datos ds.
load("data/weatherAUS.RData")
str(ds)
```

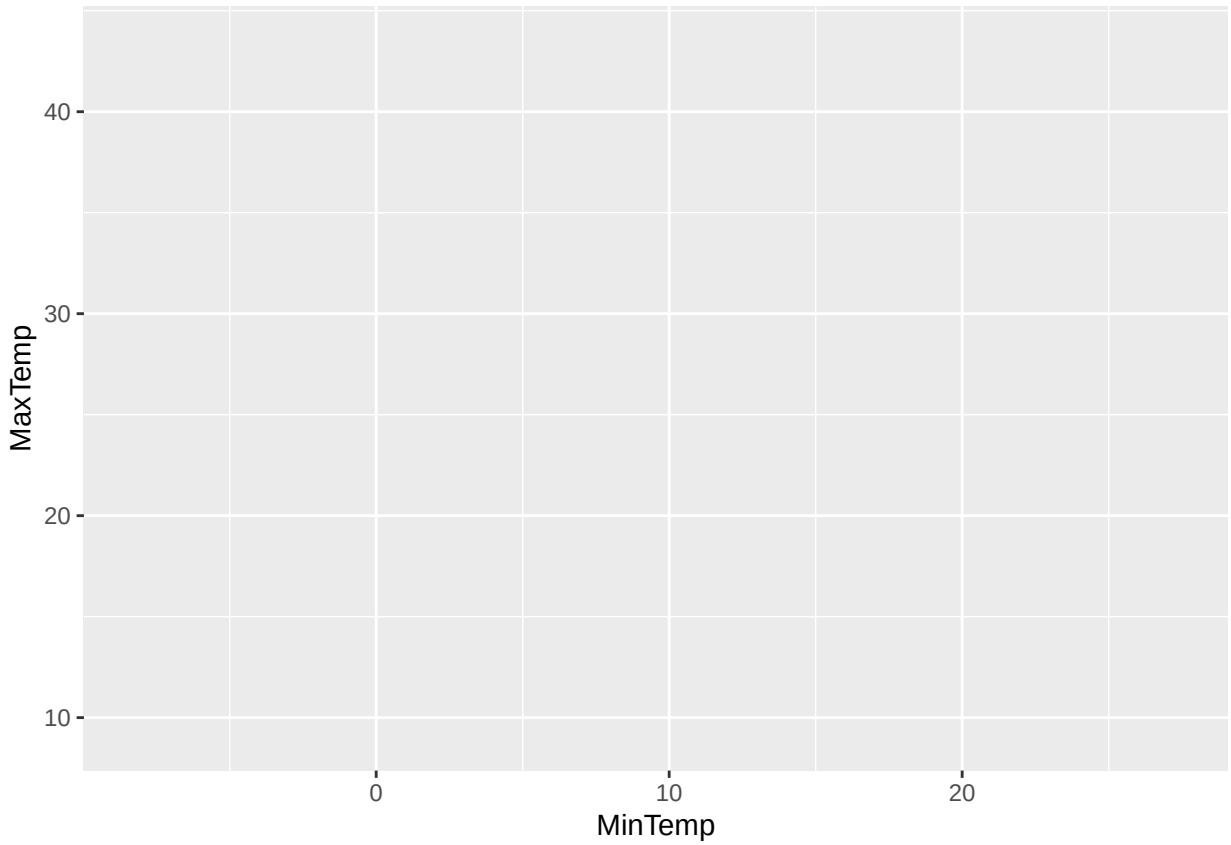
```
## 'data.frame':    863 obs. of  24 variables:
##  $ Date         : Date, format: "2009-03-23" "2014-12-08" ...
##  $ Location     : chr  "Richmond" "Albury" "Launceston" "Sale" ...
##  $ MinTemp      : num  14.2 13.9 0.4 0.2 10.2 9 8.6 24 12.4 24.4 ...
##  $ MaxTemp      : num  29.8 27.7 13.1 15.1 20.7 17.2 23.9 34.2 18 31.9 ...
##  $ Rainfall     : num  0.2 1.4 0 0.2 0 1 0 0 2 18.4 ...
##  $ Evaporation  : chr  "12.2" NA NA "1.2" ...
##  $ Sunshine     : chr  NA NA NA "7.3" ...
##  $ WindGustDir  : chr  "NE" "W" "S" "NW" ...
##  $ WindGustSpeed: int  28 37 19 17 NA 44 63 41 NA 31 ...
```

```
##  $ WindDir9am   : chr  NA "ENE" NA "WNW" ...
##  $ WindDir3pm   : chr  "E" "NW" "SSE" "NNW" ...
##  $ WindSpeed9am : int  0 6 0 9 6 22 13 15 6 11 ...
##  $ WindSpeed3pm : int  11 22 4 7 13 30 39 15 35 17 ...
##  $ Humidity9am  : int  92 74 98 93 64 71 62 71 84 83 ...
##  $ Humidity3pm  : int  36 42 57 57 40 63 22 56 61 68 ...
##  $ Pressure9am  : num  1017 1008 1028 1024 1025 ...
##  $ Pressure3pm  : num  1014 1007 1026 1021 1020 ...
##  $ Cloud9am     : int  NA NA NA 2 5 3 2 6 7 6 ...
##  $ Cloud3pm     : int  NA 5 NA 3 7 8 1 3 3 6 ...
##  $ Temp9am      : num  18.3 20.9 4.3 3.7 13 12.8 15.4 29.7 15.3 27.9 ...
##  $ Temp3pm      : num  29.5 26.4 11.9 14.3 18.7 14.6 23.5 32.1 17.5 30.9 ...
##  $ RainToday    : chr  "No" "Yes" "No" "No" ...
##  $ RISK_MM      : num  0 0 0.4 0 0 0.2 0 0 1.6 24.2 ...
##  $ RainTomorrow : chr  "No" "No" "No" "No" ...
##  - attr(*, "spec")=
##   .. cols(
##   ..   Date = col_date(format = ""),
##   ..   Location = col_character(),
##   ..   MinTemp = col_double(),
##   ..   MaxTemp = col_double(),
##   ..   Rainfall = col_double(),
##   ..   Evaporation = col_character(),
##   ..   Sunshine = col_character(),
##   ..   WindGustDir = col_character(),
##   ..   WindGustSpeed = col_integer(),
##   ..   WindDir9am = col_character(),
##   ..   WindDir3pm = col_character(),
##   ..   WindSpeed9am = col_integer(),
##   ..   WindSpeed3pm = col_integer(),
##   ..   Humidity9am = col_integer(),
##   ..   Humidity3pm = col_integer(),
##   ..   Pressure9am = col_double(),
##   ..   Pressure3pm = col_double(),
##   ..   Cloud9am = col_integer(),
##   ..   Cloud3pm = col_integer(),
##   ..   Temp9am = col_double(),
##   ..   Temp3pm = col_double(),
##   ..   RainToday = col_character(),
##   ..   RISK_MM = col_double(),
##   ..   RainTomorrow = col_character()
##   .. )
```

El dataset contiene 863 observaciones meteorológicas de distintas localidades australianas y 24 variables, como temperaturas, precipitaciones, viento, humedad y presión, con algunos valores ausentes (`NA`).
La variable `Year` agrupa los registros en 11 años y permite comparar las distribuciones de `MinTemp` y `MaxTemp` por año.

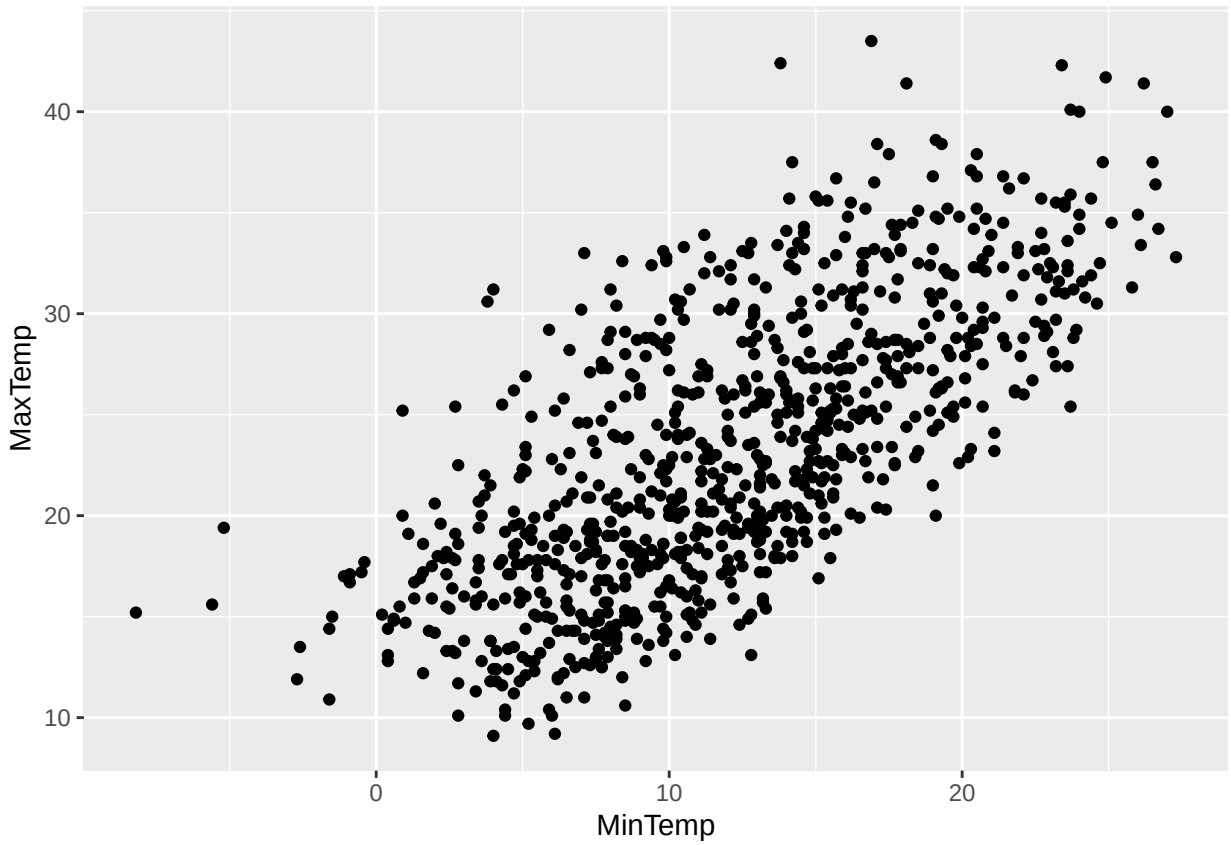
Creo un objeto ggplot denominado grafico1 en el que esté definido el conjunto de datos ds alojado en el fichero weatherAUS.RData y un aesthetics en el que en el eje x esté definida la variable MinTemp y en el eje y esté definida la variable MaxTemp.

```r
# Definimos los datos y las variables de los ejes.
grafico1 <- ggplot(data = ds, aes(x = MinTemp, y = MaxTemp))
grafico1
```



Añado los puntos para construir un gráfico de dispersión de las variables MinTemp y MaxTemp.

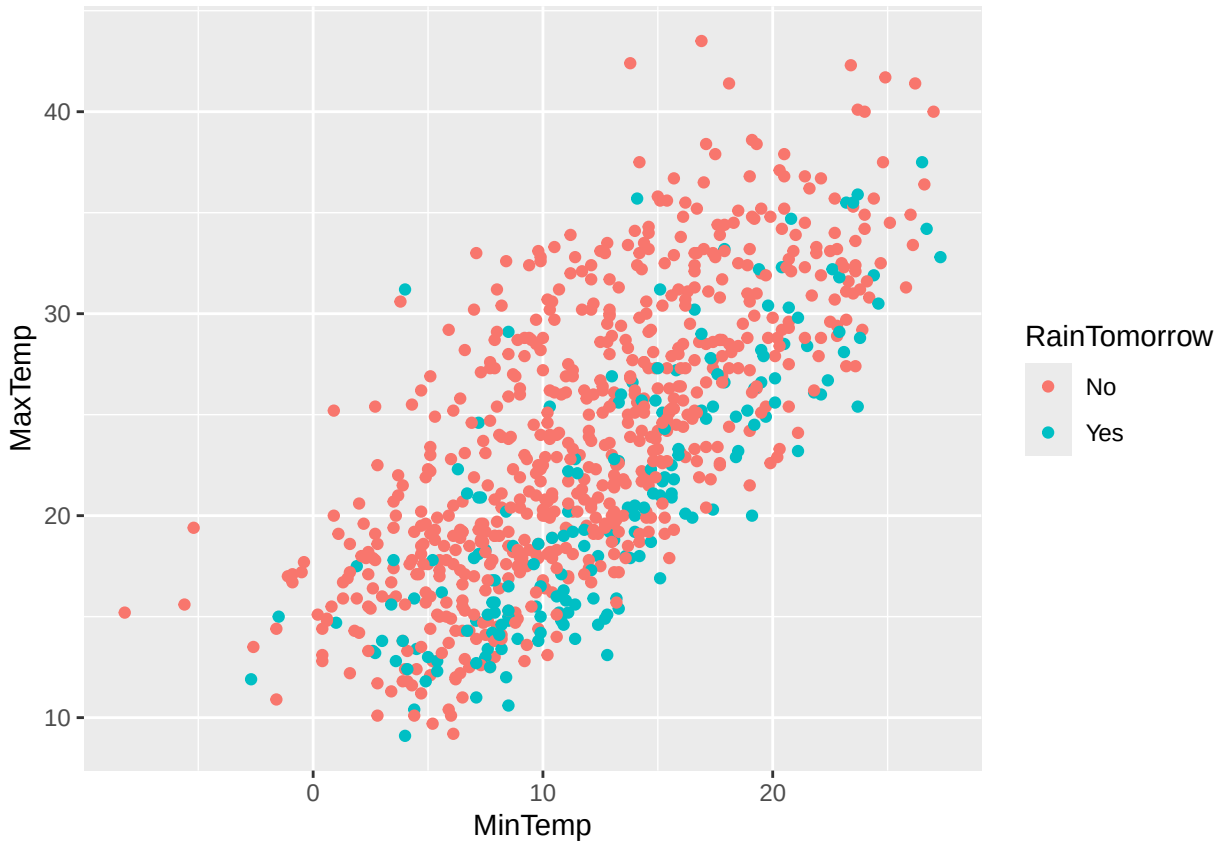
```
# Añadimos los puntos para representar el gráfico de dispersión.
grafico1 + geom_point()
```



El gráfico de dispersión relaciona la temperatura mínima (MinTemp, eje X) con la máxima (MaxTemp, eje Y); cada punto representa una observación meteorológica. Se aprecia una relación positiva: cuanto mayor es la temperatura mínima, mayor suele ser la máxima, aunque existe variabilidad entre las observaciones.

Genero el mismo gráfico y lo almaceno en grafico2 definiendo el aesthetics para visualizar las variables MinTemp y MaxTemp en los ejes de la gráfica y la variable categórica RainTomorrow como el color. A partir de este, represento un gráfico de dispersión en el que se muestren los puntos con el color del punto correspondiente a la variable RainTomorrow.

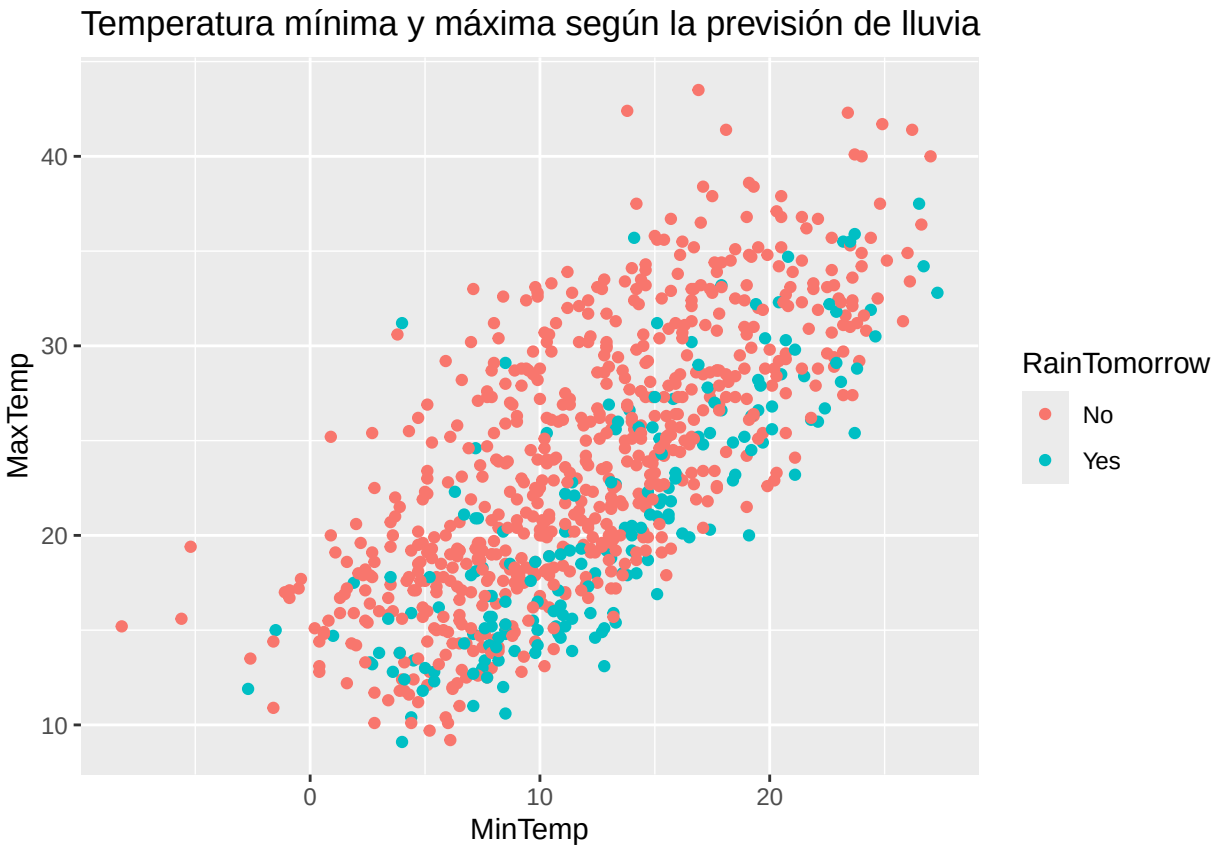
```
# Definimos RainTomorrow como variable que determina el color.
grafico2 <- ggplot(
  data = ds,
  aes(x = MinTemp, y = MaxTemp, color = RainTomorrow)
) + geom_point()
grafico2
```



Los puntos turquesa (Yes) tienden a presentar máximas más bajas para mínimas similares, aunque ambas categorías se solapan ampliamente.

Ponemos el titulo con la funcion ggtitle y lo guardamos en una variable nueva.

```
grafico3 <- grafico2 +
  ggtitle("Temperatura mínima y máxima según la previsión de lluvia")
grafico3
```



Guardamos la ultima grafica como PDF en la carpeta de results.

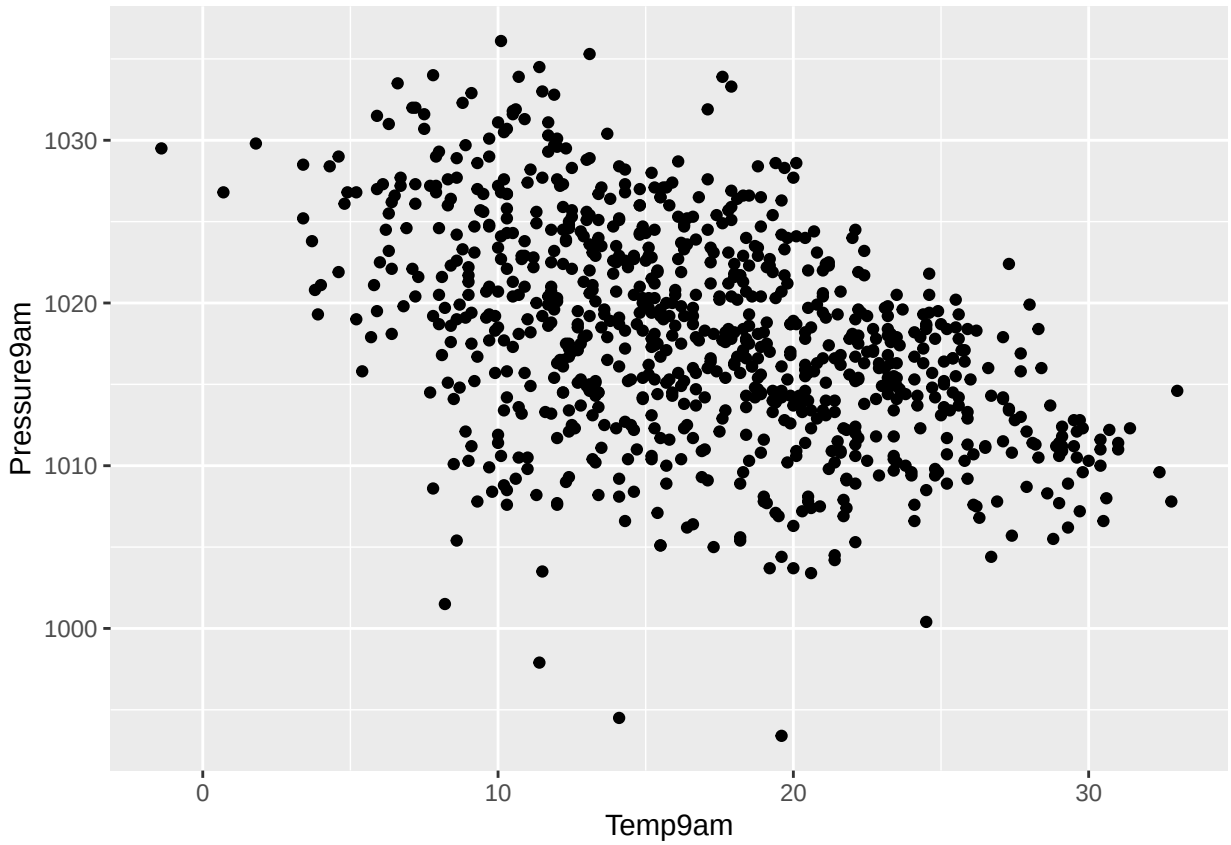
```
# Exportamos explícitamente grafico3 a PDF.
ggsave(
  filename = "./results/Ejercicio1.pdf",
  plot = grafico3
)
```

```
## Saving 6.5 x 4.5 in image
```

1.2. Ejercicio 2

Scatter Plot de Temp9am y Pressure9am en los ejes x e y respectivamente.

```
grafico <- ggplot(ds, aes(x = Temp9am, y = Pressure9am)) +
  geom_point()
grafico
```

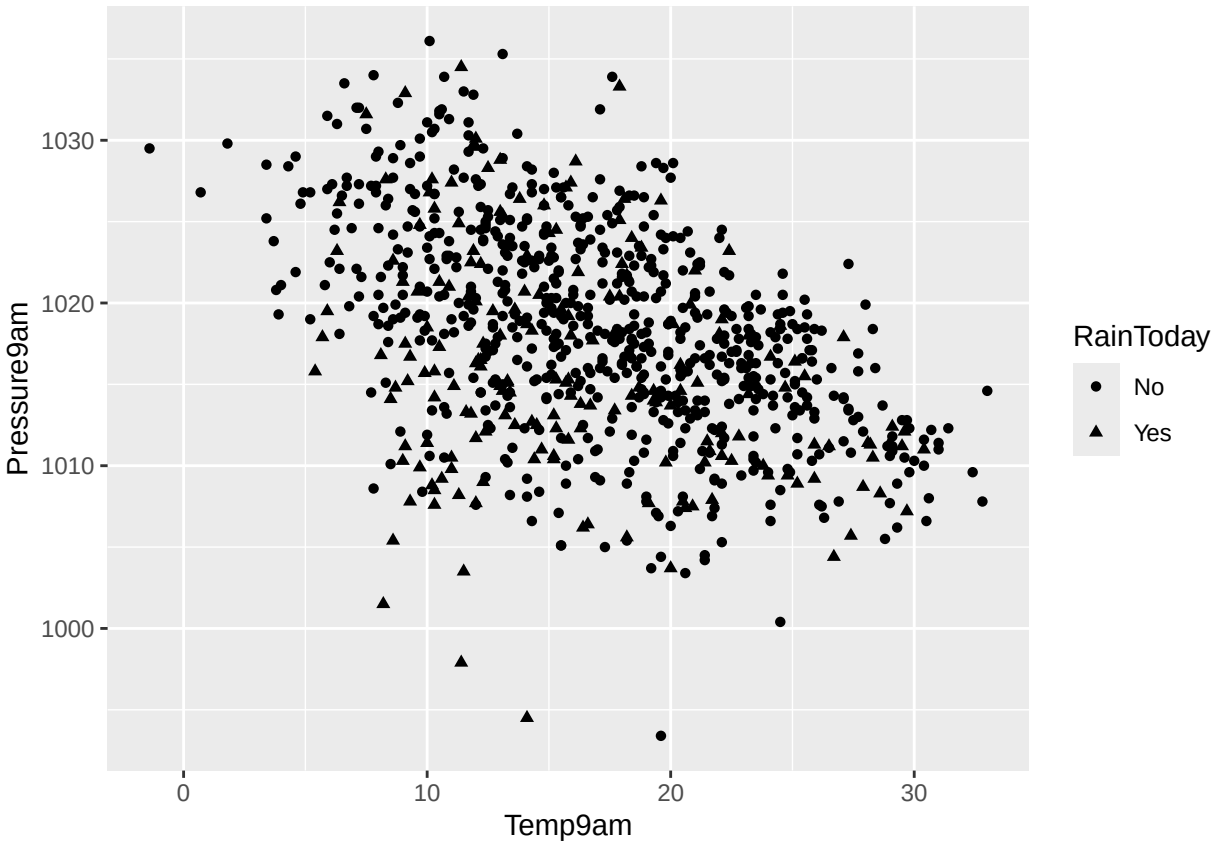


El gráfico relaciona la temperatura (`Temp9am`) con la presión atmosférica (`Pressure9am`) a las 9:00.
Se observa una relación negativa: a mayor temperatura, la presión tiende a ser menor, aunque existe dispersión y algunos valores extremos.

Añadimos diferentes tipos de punto para representar RainToday

```
# Representamos RainToday mediante la forma del punto.
grafico_forma <- ggplot(
  ds,
  aes(x = Temp9am, y = Pressure9am, shape = RainToday)
) +
  geom_point()

grafico_forma
```

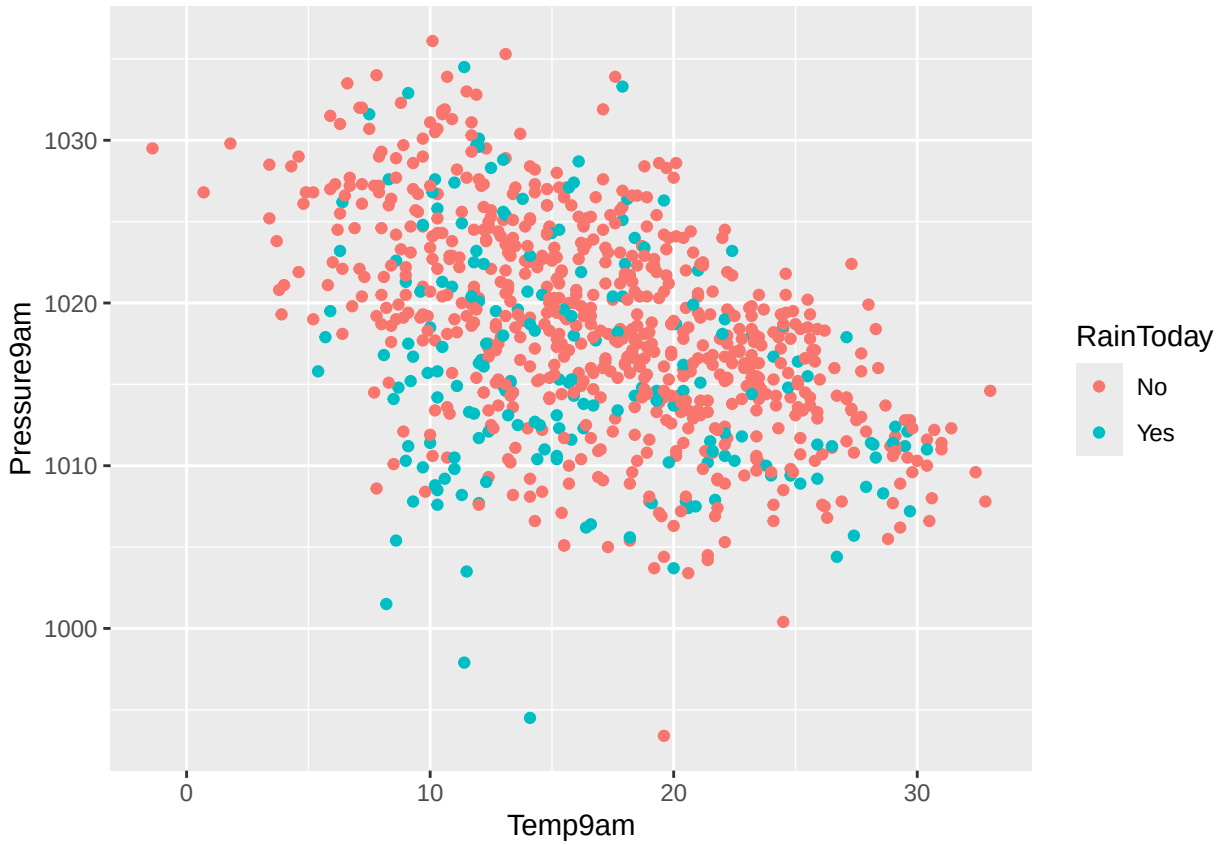


La forma de los puntos diferencia los días con lluvia de los días sin lluvia (`RainToday`), pero la superposición de muchos puntos dificulta distinguir las categorías.

Realizamos el mismo proceso pero ahora con el color:

```
grafico_color <- ggplot(
  ds,
  aes(x = Temp9am, y = Pressure9am, color = RainToday)
) +
  geom_point()

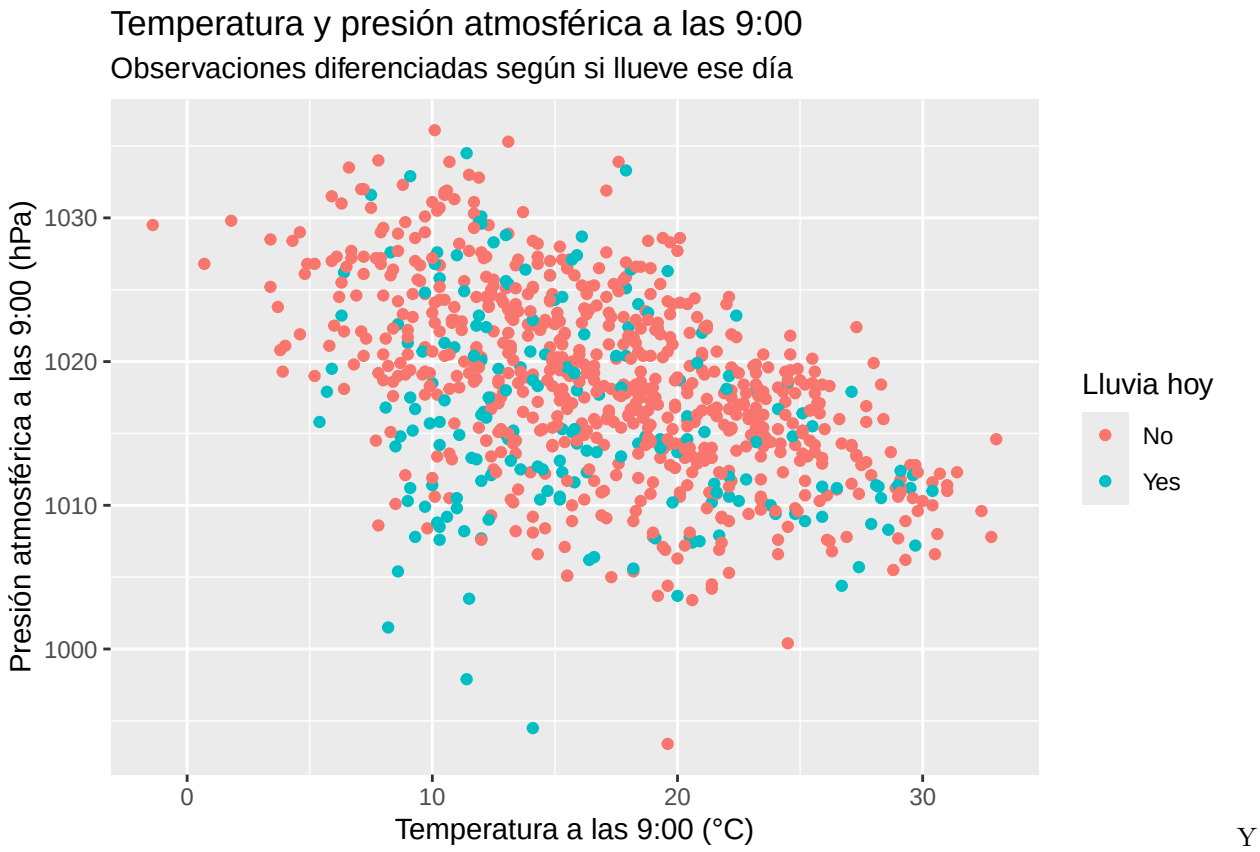
grafico_color
```



Vemos como se aprecia mucho mejor la diferencia con el color, con la forma queda confuso y no se entiende correctamente, en cambio con el color con un vistazo ya difrencias bien los 2 grupos. Finalmente añadimos titulos e informacion necesaria a la grafica del color:

```
# Añadimos título, subtítulo, etiquetas de los ejes y de la leyenda.
grafico_color <- grafico_color +
  labs(
    title = "Temperatura y presión atmosférica a las 9:00",
    subtitle = "Observaciones diferenciadas según si llueve ese día",
    x = "Temperatura a las 9:00 (°C)",
    y = "Presión atmosférica a las 9:00 (hPa)",
    color = "Lluvia hoy"
  )

grafico_color
```



Y

guardamos la grafica final en resultados.

```
ggsave(
  filename = "./results/Ejercicio2.pdf",
  plot = grafico_color
)
```

```
## Saving 6.5 x 4.5 in image
```

1.3. Ejercicio 3

Cargamos el Dataset desde data y visualizamos el tipo de las variables del dataset.

```
# Cargamos los datos y consultamos su estructura.
load("data/iris_tidy.Rdata")

str(iris.tidy)
```

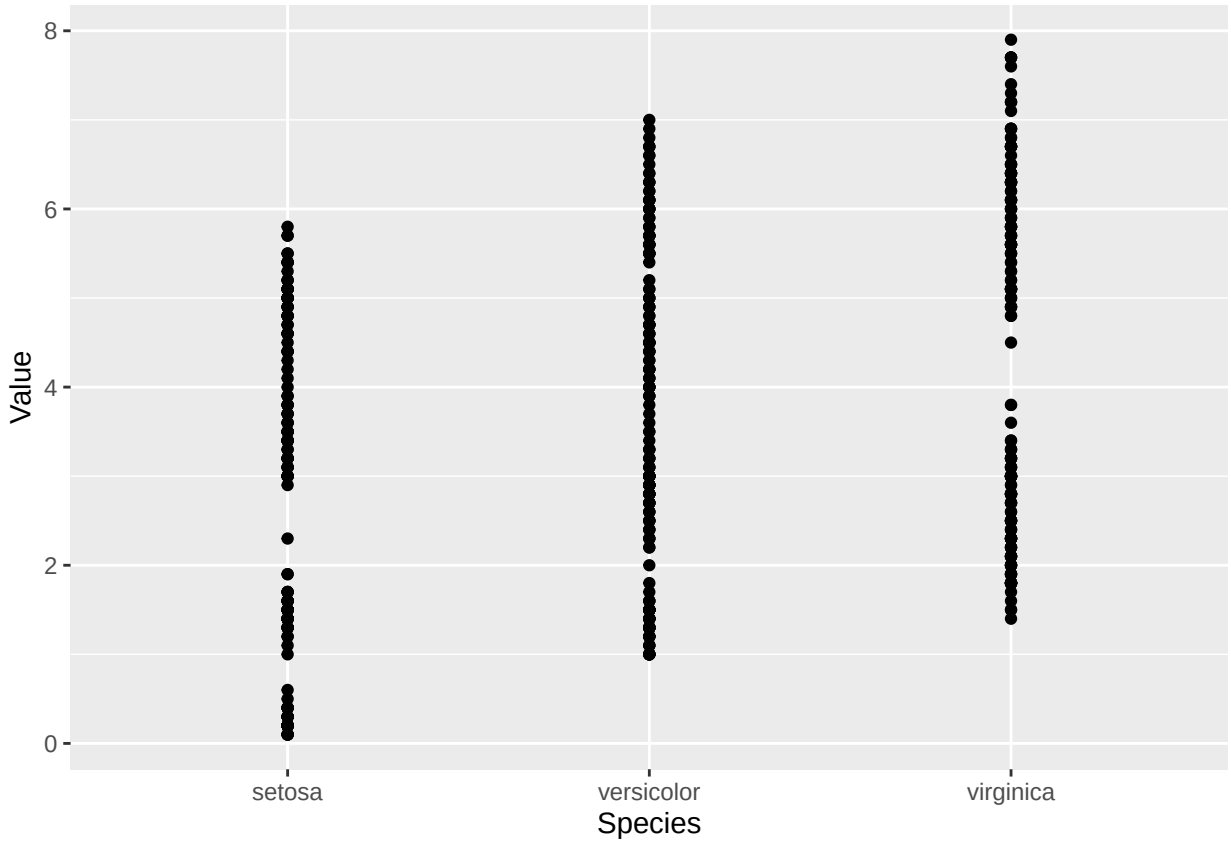
```
## 'data.frame':    600 obs. of  4 variables:
##  $ Species: Factor w/ 3 levels "setosa","versicolor",..: 1 1 1 1 1 1 1 1 1 1 ...
##  $ Part   : Factor w/ 2 levels "Petal","Sepal": 2 2 2 2 2 2 2 2 2 2 ...
##  $ Measure: chr  "Length" "Length" "Length" "Length" ...
##  $ Value  : num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
```

El dataset contiene 600 observaciones y 4 columnas: `Species` identifica la especie de iris y `Part` indica si la medida corresponde al pétalo o al sépalo.
`Measure` distingue entre longitud (`Length`) y anchura (`Width`), mientras que `Value` recoge el valor de cada medida en centímetros.

Creamos un objeto ggplot denominado iris.grafico1 en el que esté definido el conjunto de datos iris.tidy y un

aesthetics en el que en el eje x esté definida la variable Species y en el eje y esté definida la variable Value y añadimos una capa de puntos para construir un gráfico de dispersión de las variables Species y Value.

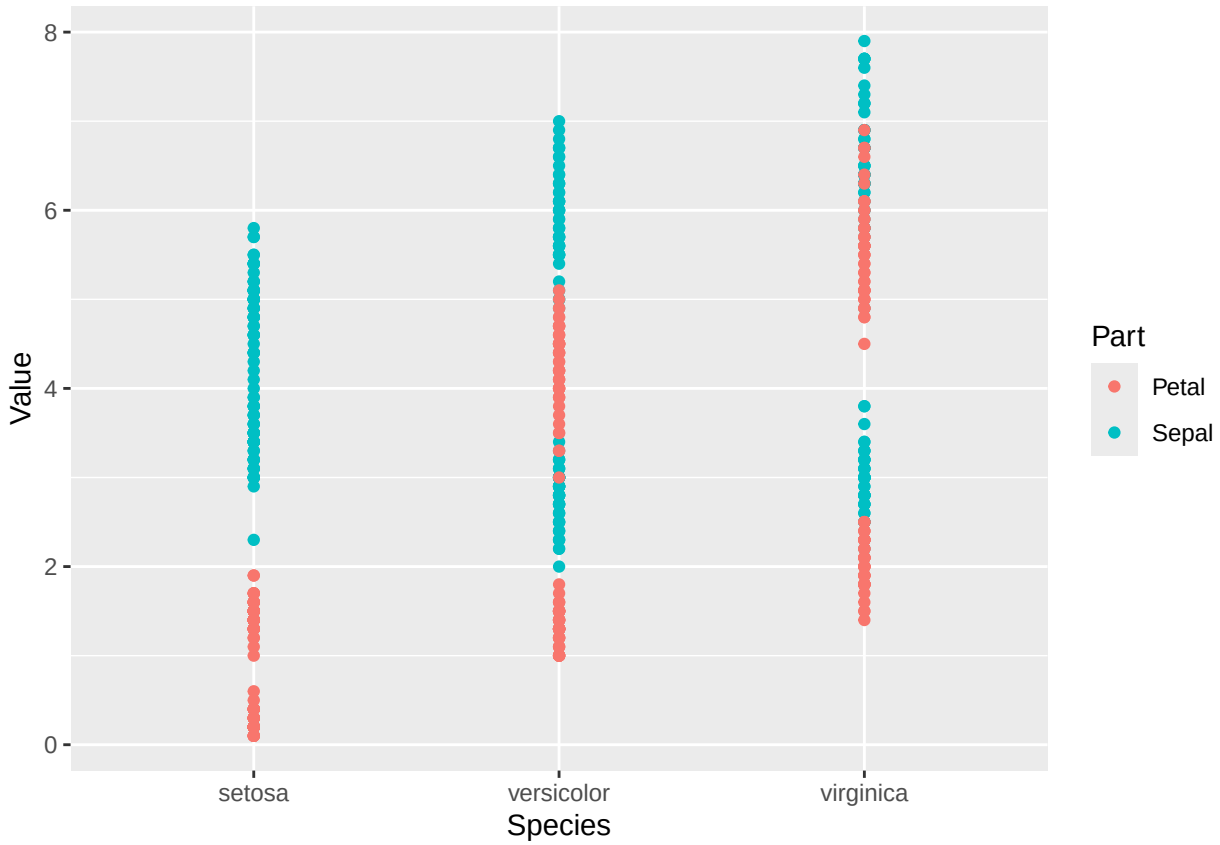
```
iris.grafico1 <- ggplot(
  data = iris.tidy,
  aes(x = Species, y = Value)
)  +
  geom_point()
iris.grafico1
```



Al ser Specie una variable categorica se ven como columnas en el grafico. Posteriormnete añadimos Part como variable que determina el color

```
# Añadimos Part como variable que determina el color.
iris.grafico2 <- iris.grafico1 +
  aes(color = Part)

iris.grafico2
```

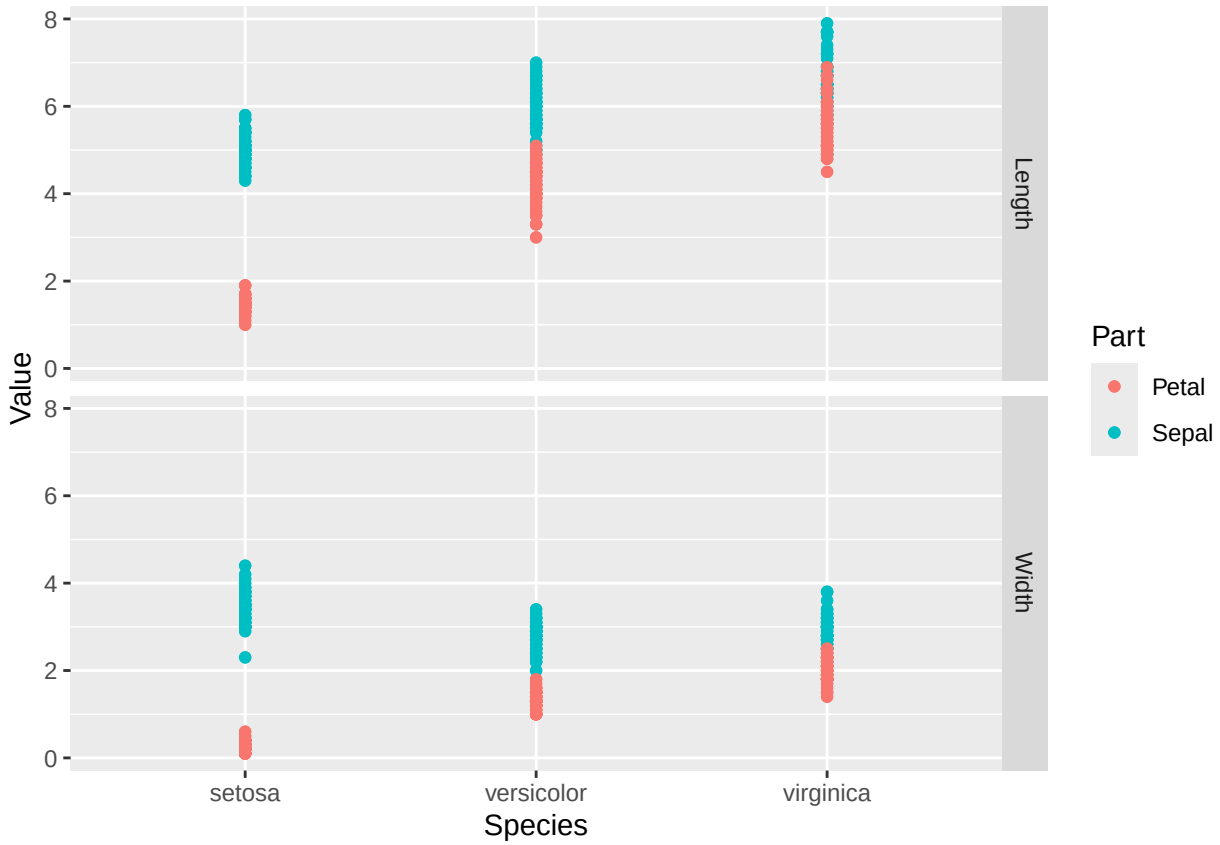


Si bien se aprecian diferencias entre el petalo y el sepalo con los colores, visualizando asi la grafica se superponen muchos puntos y no permiten extraer conclusiones claras.

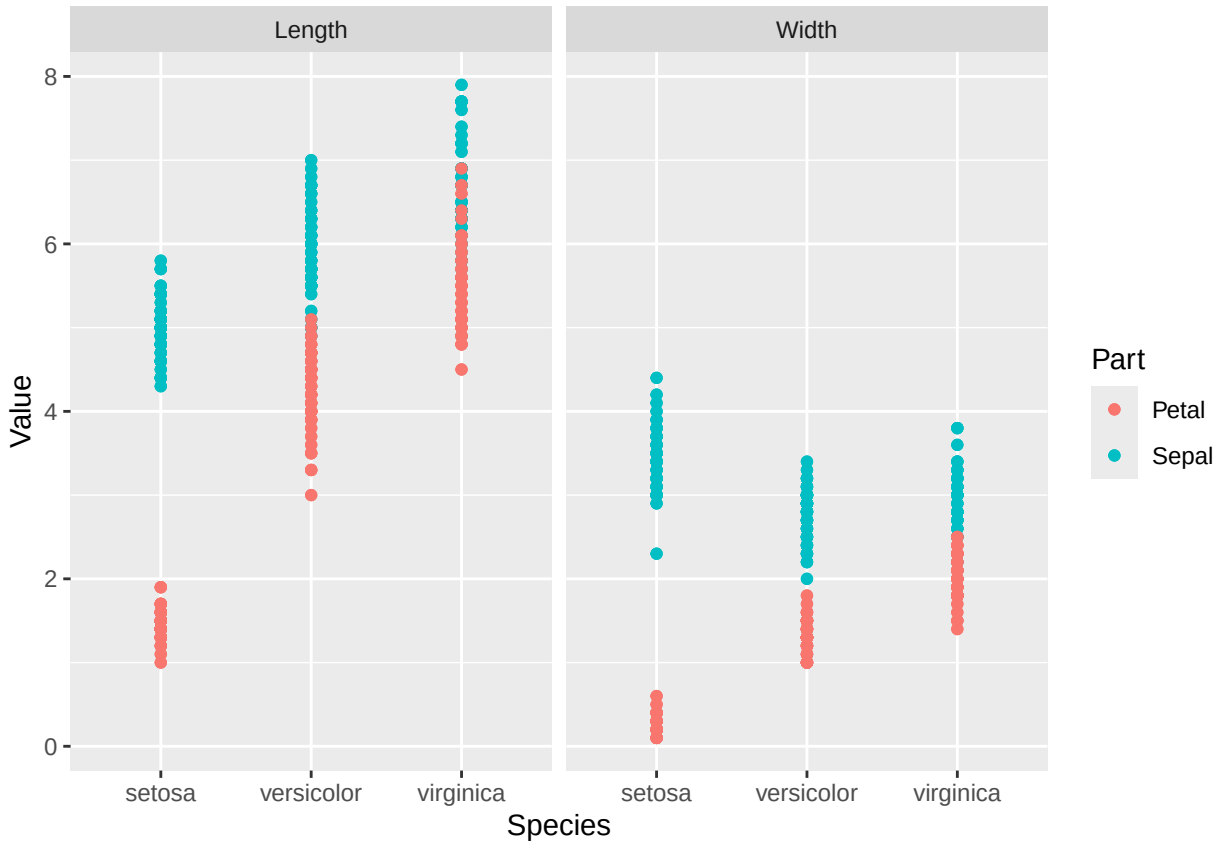
```
#Ayuda de facet
#help(facet_grid)
```

```
# Separamos los valores de Measure en filas.
iris.filas <- iris.grafico2 +
  geom_point() +
  facet_grid(Measure ~ .)

iris.filas
```



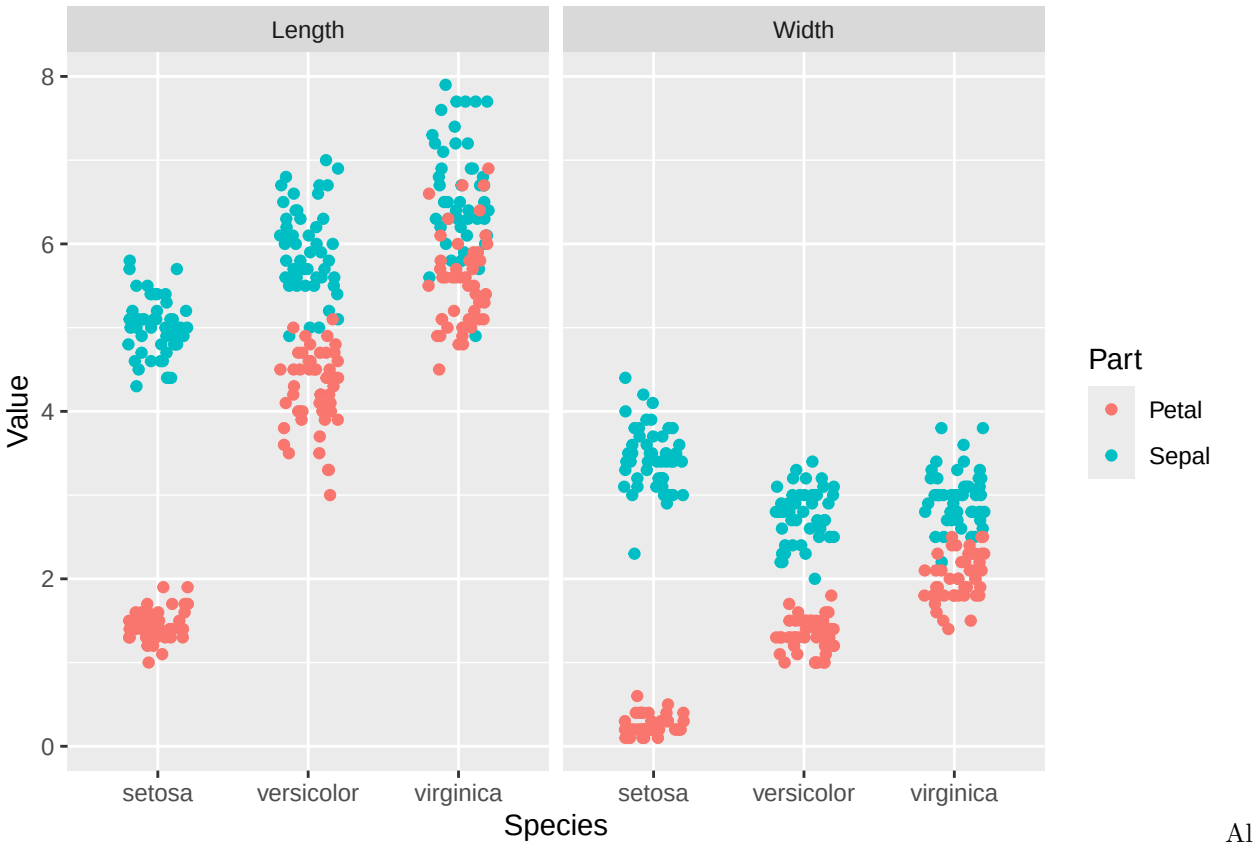

```
iris.columnas <- iris.grafico2 +
  geom_point() +
  facet_grid(. ~ Measure)
iris.columnas
```



A mi parecer se entiende mejor la informacion cuando el grid se ve en columnas, la disposición en columnas facilita comparar los valores de las dos medidas, porque los paneles comparten el eje vertical y una misma altura representa el mismo valor. Ahora añado ruido a las variable categorica con geom_jitter pero solo de ancho, ya que alto desvirtuaria los datos. Al separar por ancho y largo si se aprecian mas las diferencias entre sepalo y petalo.

```
iris.final <- ggplot(
  data = iris.tidy,
  aes(x = Species, y = Value, color = Part)
)  +
  geom_jitter(width = 0.2, height = 0)  +
  facet_grid(. ~ Measure)

iris.final
```



Al añadir el ruido se aprecia mejor el numero de instancias que hay en cada grupo y altura sin modificar los datos ya que la altura se conserva, permitiendo visaulizar mejor una variable categorica. Con esto si se aprecia correctamnete la diferencicacion como 2 grupos separados.

```
ggsave(
  filename = "./results/Ejercicio3.pdf",
  plot = iris.final
)
```

```
## Saving 6.5 x 4.5 in image
```

1.4. Ejercicio 4

Cargamos y visualizamos el dataset del ejercicio 4

```
load("data/Ejercicio4_Data.Rdata")

str(DatosEjer4)
```

```
## 'data.frame':    200 obs. of  3 variables:
##  $ Fecha     : Date, format: "2002-01-01" "2002-02-01" ...
##  $ Fabricante: Factor w/ 2 levels "Microsoft","Apple": 1 1 1 1 1 1 1 1 1 1 ...
##  $ Ventas    : num  75 67.1 75.5 77.4 68.1 ...
```

Tiene 3 columnas, Fecha de la venta en formato Date el fabricante como Factor y las ventas como numero decimal

```
grafico_puntos <- ggplot(
  DatosEjer4,
  aes(x = Fecha, y = Ventas, color = Fabricante)
```

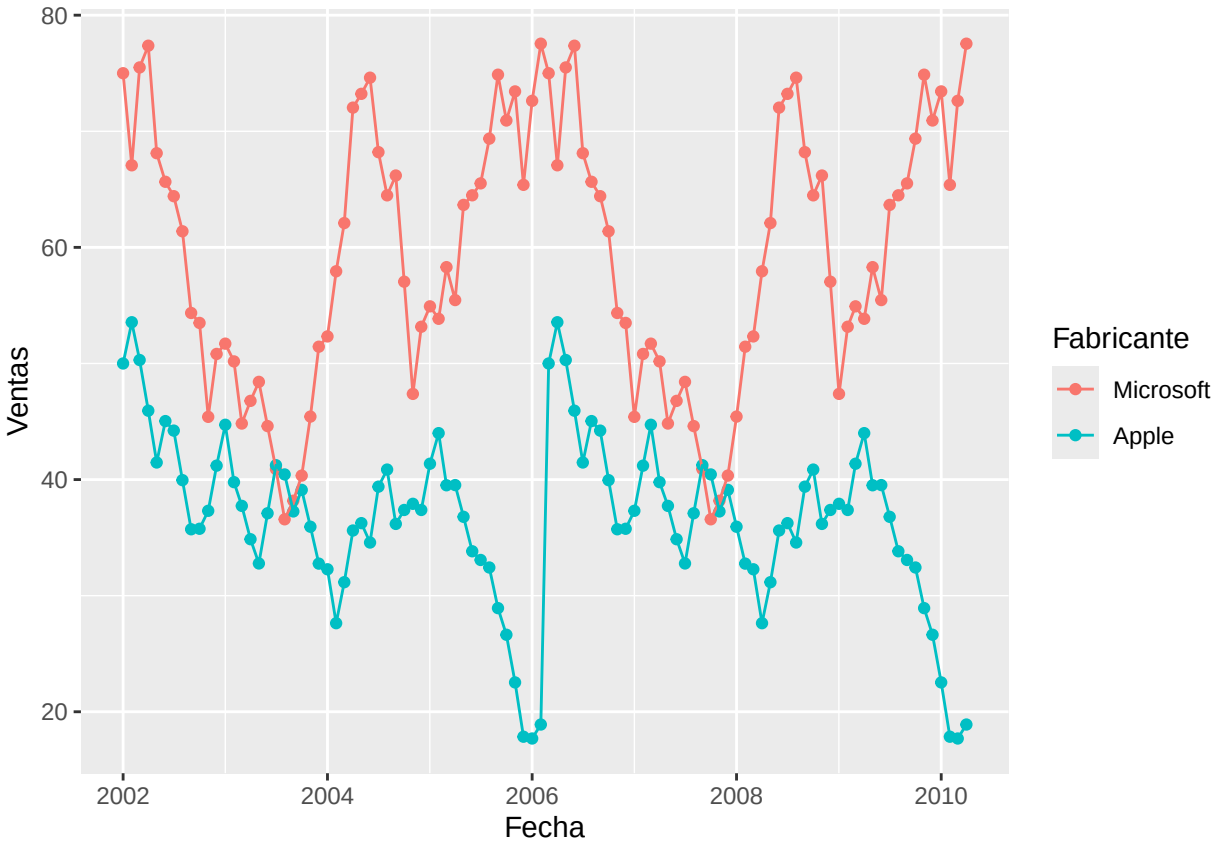
```
) +
  geom_point()

grafico_puntos
```



El gráfico de puntos permite observar las ventas en cada fecha, pero con tanto punto queda confuso la evolucion del tiempo de ventas, por tanto otros tipos de grafica ayudarian mejor a expresar ese concepto. Por tanto represento un gráfico como el anterior en el que se muestran la línea que une los puntos que antes he representado.

```
grafico_lineas <- grafico_puntos +
  geom_line(aes(group = Fabricante))
grafico_lineas
```

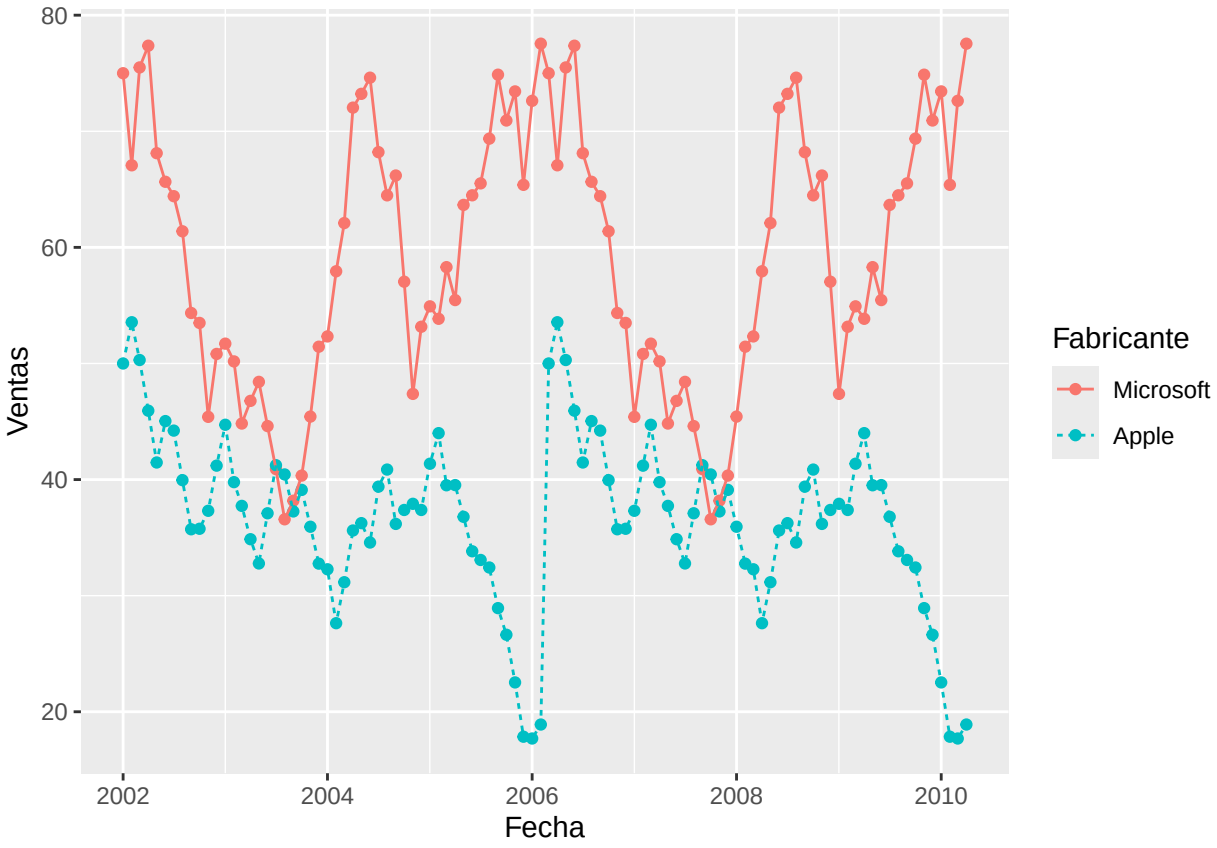


Las líneas facilitan seguir la evolución de cada fabricante y comparar sus cambios, expresando mejor la idea de la evolucion de las ventas en el timepo.

Ahora cambio el grafico para que cada fabricante tenga un tipo linea a parte:

```
grafico_tipo_linea <- grafico_puntos +
  geom_line(
    aes(group = Fabricante, linetype = Fabricante)
  )

grafico_tipo_linea
```

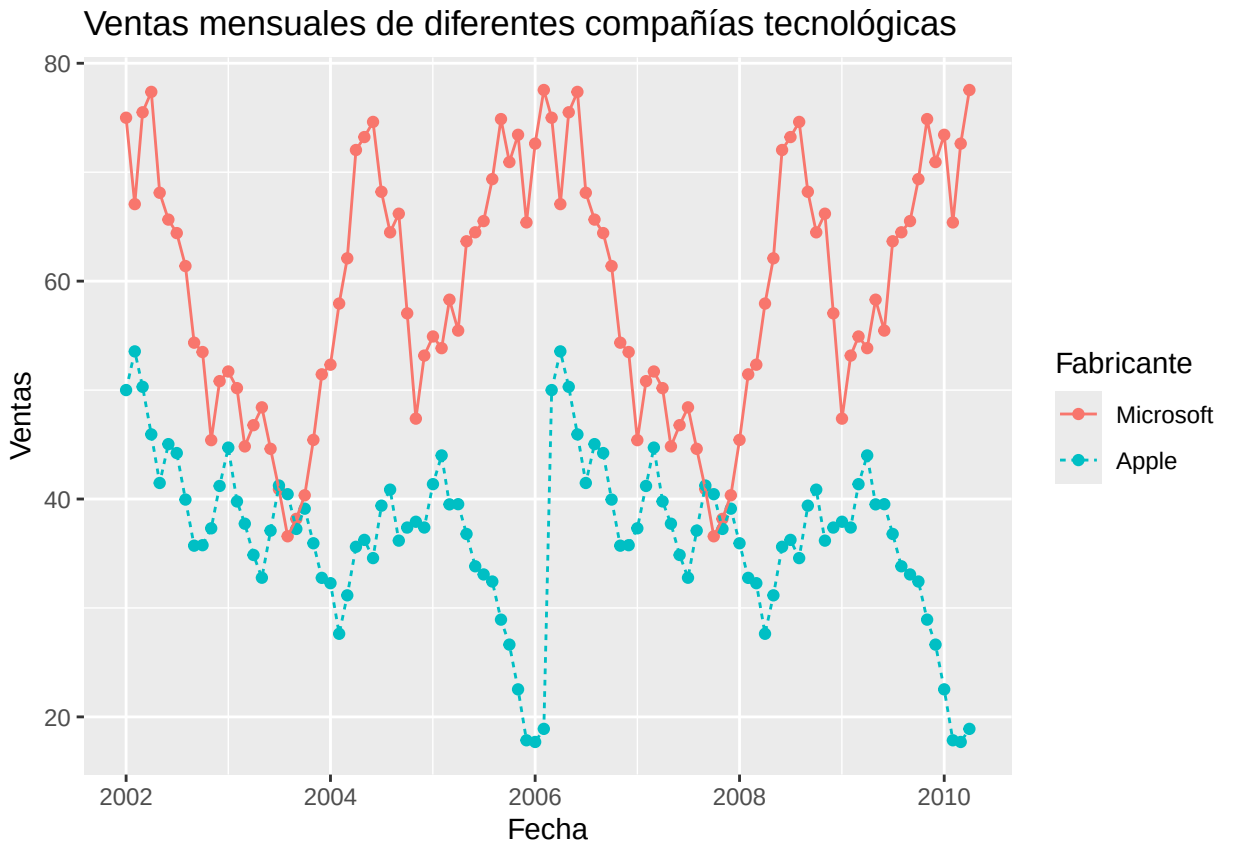


En esta grafica se aprecia mejor las tendencias de las Ventas vemos como Microsoft vende mas, tambien se aprecia una cierta correlacion expecto del 2009 hacia delante donde cambian de comportamiento.

Añado los titulos y subtitulos necesarios, finalmnete lo guardo como PDF en /results:

```
grafico_final <- grafico_tipo_linea + labs(
    title = "Ventas mensuales de diferentes compañías tecnológicas",
    x = "Fecha",
    y = "Ventas",
    color = "Fabricante",
    linetype = "Fabricante"
  )

grafico_final
```




```
ggsave(
  filename = "./results/Ejercicio4.pdf",
  plot = grafico_final
)
```

```
## Saving 6.5 x 4.5 in image
```

```
load("data/Experimento.Rdata")

str(Experimento)
```

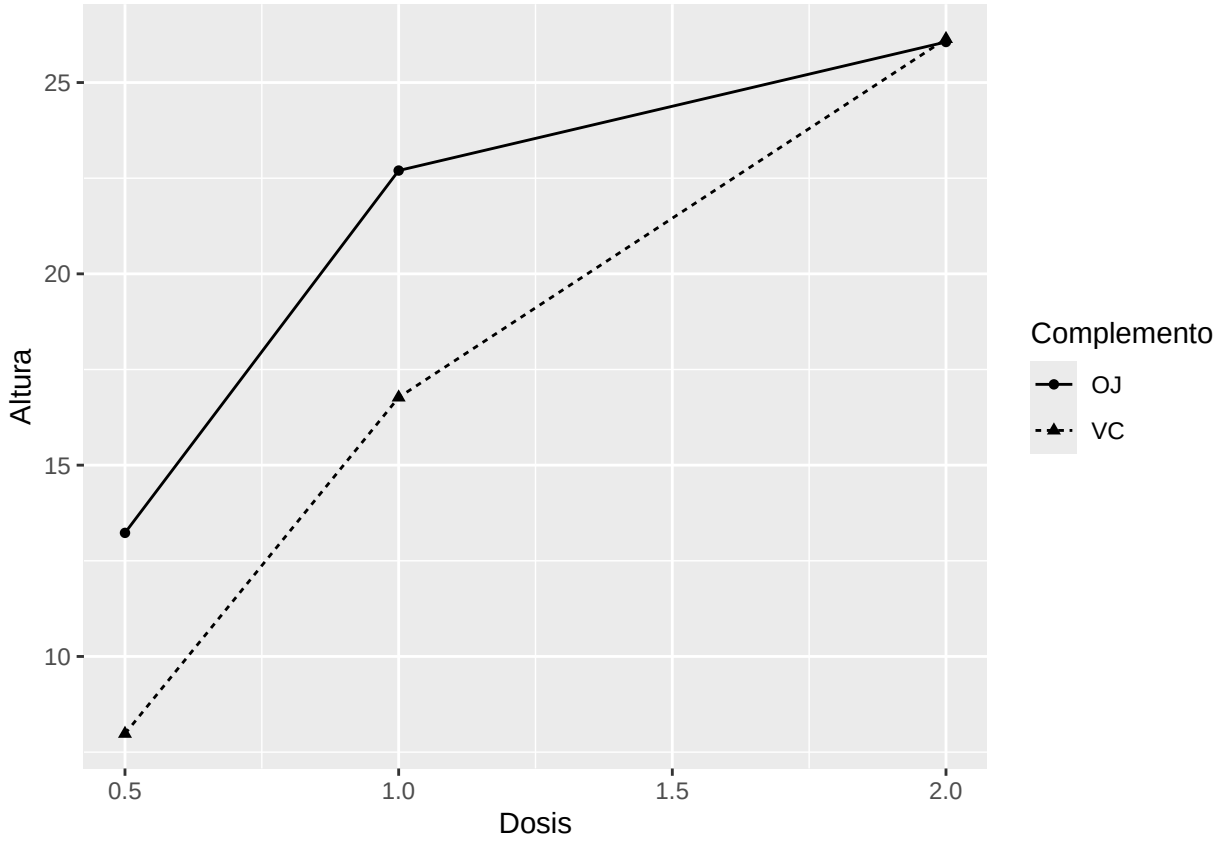
```
## 'data.frame':    6 obs. of  4 variables:
##  $ Complemento : Factor w/ 2 levels "OJ","VC": 1 1 1 2 2 2
##  $ Dosis       : num  0.5 1 2 0.5 1 2
##  $ Altura      : num  13.23 22.7 26.06 7.98 16.77 ...
##  $ Error_Altura: num  4.46 3.91 2.66 2.75 2.52 ...
```

El dataset contiene 6 observaciones y 4 columnas: Complemento (OJ o VC), Dosis administrada, Altura media y Error_Altura asociado.

```
#Gráfico con puntos y una línea de distinto trazo por complemento.
grafico1 <- ggplot(
  Experimento,
  aes(
    x = Dosis,
    y = Altura,
    group = Complemento,
    linetype = Complemento,
    shape = Complemento
```

```
  )
) +
  geom_point() +
  geom_line()

grafico1
```

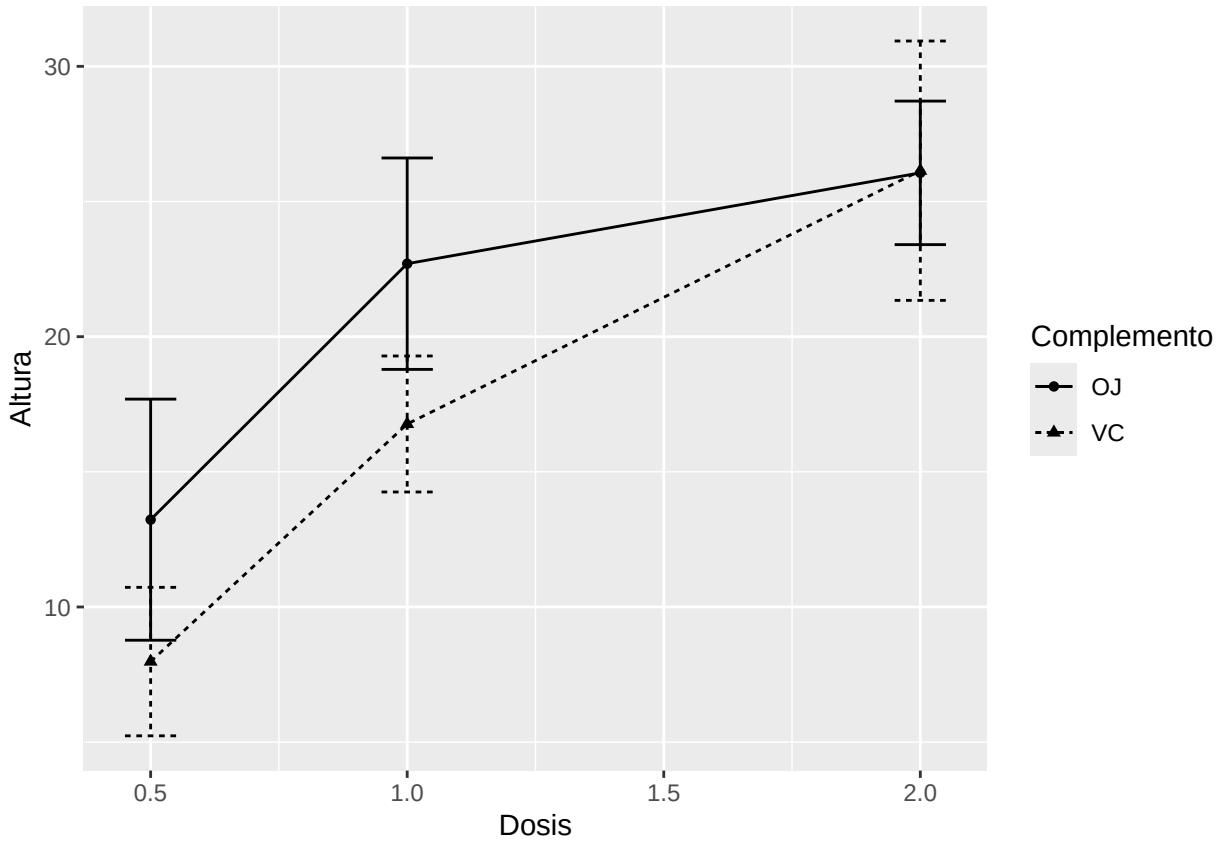


El código asigna Dosis al eje X y Altura al eje Y, diferencia cada Complemento mediante linetype y shape dentro de aes(), y dibuja los puntos y las líneas con geom_point() y geom_line(). La altura aumenta con la dosis en ambos complementos; OJ presenta valores mayores en las dosis bajas, pero ambos alcanzan una altura similar con la dosis de 2.

```
#help(geom_errorbar)
```

```
grafico2 <- grafico1 + geom_errorbar(
    aes(
      ymin = Altura - Error_Altura,
      ymax = Altura + Error_Altura
    ),
    width = 0.1)

grafico2
```

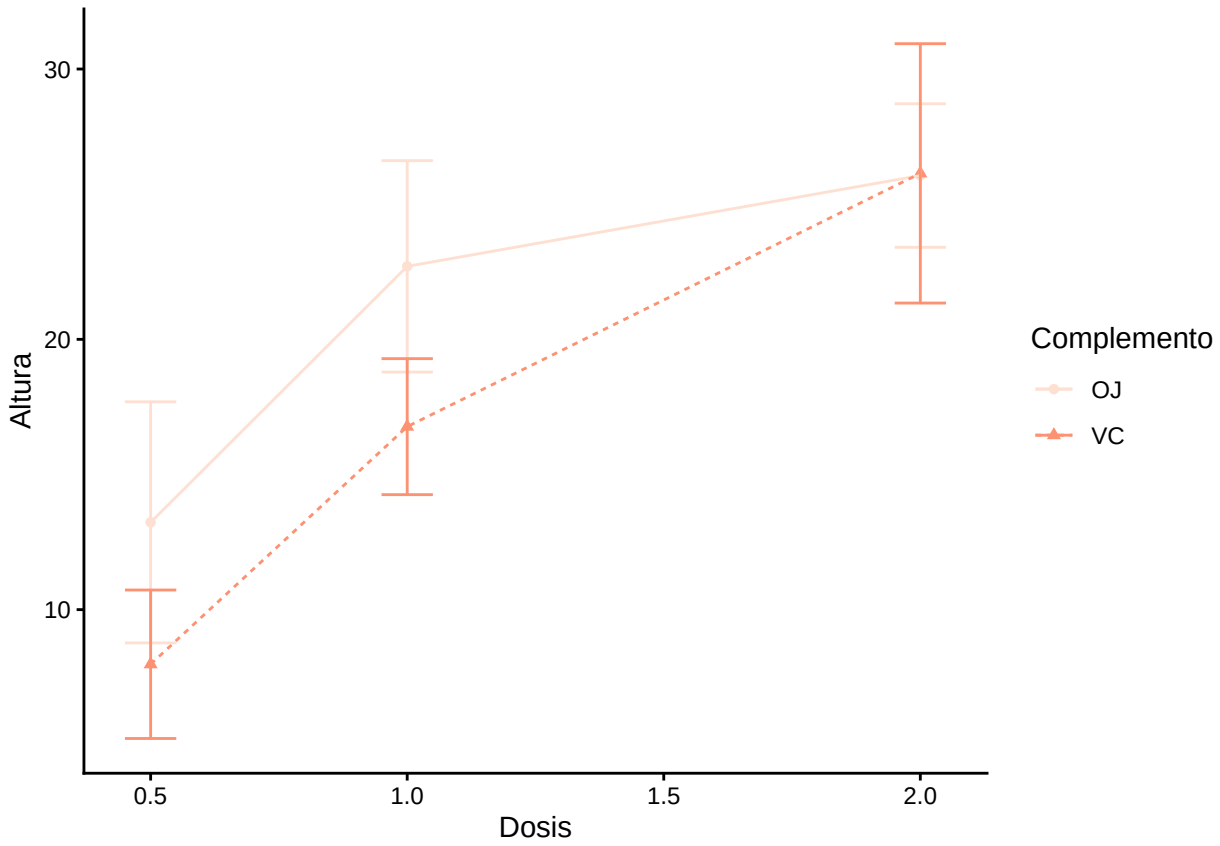


Se mantiene la tendencia anterior, pero las barras muestran la variabilidad de las alturas y su solapamiento, OJ presenta mas error excepro en la dosis 2, donde ambos complementos presentan medias similares, y OJ reduce el error.

Definiendo forma y tipo de línea en sus propias capas. Añadimos color por complemento y una paleta de tonos rojos.

```
grafico3 <- ggplot(
  Experimento,
  aes(
    x = Dosis,
    y = Altura,
    group = Complemento,
    color = Complemento
  )
) +
  geom_point(aes(shape = Complemento)) +
  geom_line(aes(linetype = Complemento)) +
  geom_errorbar(
    aes(
      ymin = Altura - Error_Altura,
      ymax = Altura + Error_Altura
    ),
    width = 0.1
  ) +
  scale_color_brewer(palette = "Reds") + theme_classic()

grafico3
```



Añado theme clasico porque sino la paleta de rojos no se visualiza correctamnete.

```
ggsave(
  filename = "./results/Ejercicio5.pdf",
  plot = grafico3
)
```

```
## Saving 6.5 x 4.5 in image
```

1.5. Ejercicio 6

```
load("data/iceRiver.RData")

str(ice.river.df)
```

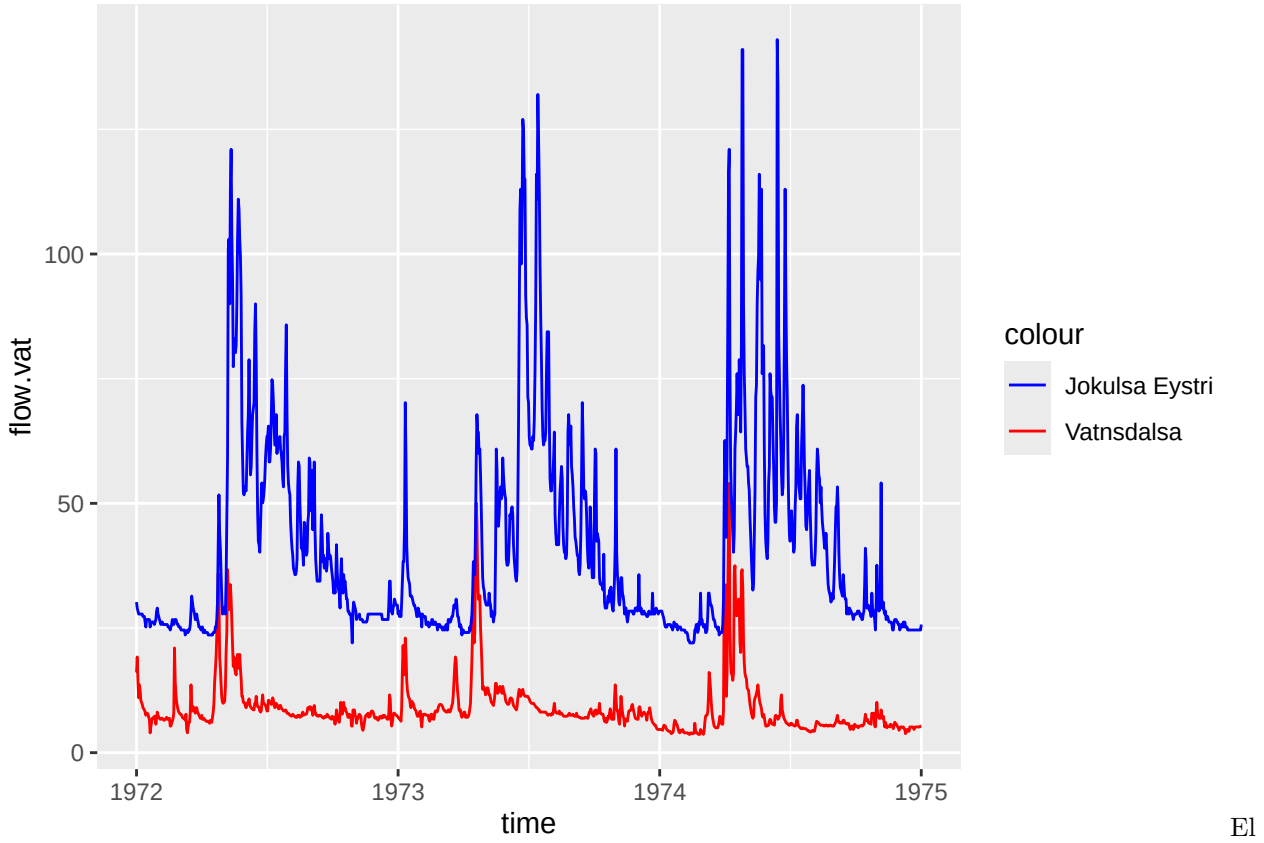
```
## 'data.frame':    1096 obs. of  5 variables:
##  $ flow.vat: num  16.1 19.2 14.5 11 13.6 12.5 10.5 10.1 9.68 9.02 ...
##  $ flow.jok: num  30.2 29 28.4 27.8 27.8 27.8 27.8 27.8 27.8 27.3 ...
##  $ prec    : num  8.1 4.4 7 0 0 0 1.9 1.2 0 0.1 ...
##  $ temp    : num  0.9 1.6 0.1 0.6 2 0.8 1.4 1.3 2.2 0.1 ...
##  $ time    : num  1972 1972 1972 1972 1972 ...
```

```
#?tseries::ice.river
```

El dataset contiene los registros diarios de 1972 a 1974: `flow.vat` y `flow.jok` representan el caudal medio de los ríos Vatnsdalsa y Jokulsa Eystri, en m^3/s.
Las columnas `prec` y `temp` recogen la precipitación diaria (mm) y la temperatura media diaria (°C) en Hveravellir.

```
grafico <- ggplot(ice.river.df, aes(x = time)) +
  geom_line(aes(y = flow.vat, color = "flow.vat")) +
  geom_line(aes(y = flow.jok, color = "flow.jok")) +
  scale_color_manual(
    values = c("flow.vat" = "red", "flow.jok" = "blue"),
    labels = c("flow.vat" = "Vatnsdalsa", "flow.jok" = "Jokulsa Eystri")
  )

grafico
```



El río Jokulsa Eystri presenta un caudal mayor y fluctuaciones más pronunciadas que el Vatnsdalsa durante todo el período.
Ambos muestran picos en épocas similares de cada año, lo que sugiere un patrón estacional.

```
grafico_leyenda <- grafico + labs(
    title = "Caudal diario de dos ríos islandeses",
    subtitle = "Evolución durante el período 1972-1974",
    x = "Año",
    y = "Caudal medio diario (m³/s)",
    color = "Río"
  )

grafico_leyenda
```

```
## Warning in grid.Call(C_textBounds, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <e2>
```

```
## Warning in grid.Call(C_textBounds, as.graphicsAnnot(x$label), x$x, x$y, :
```

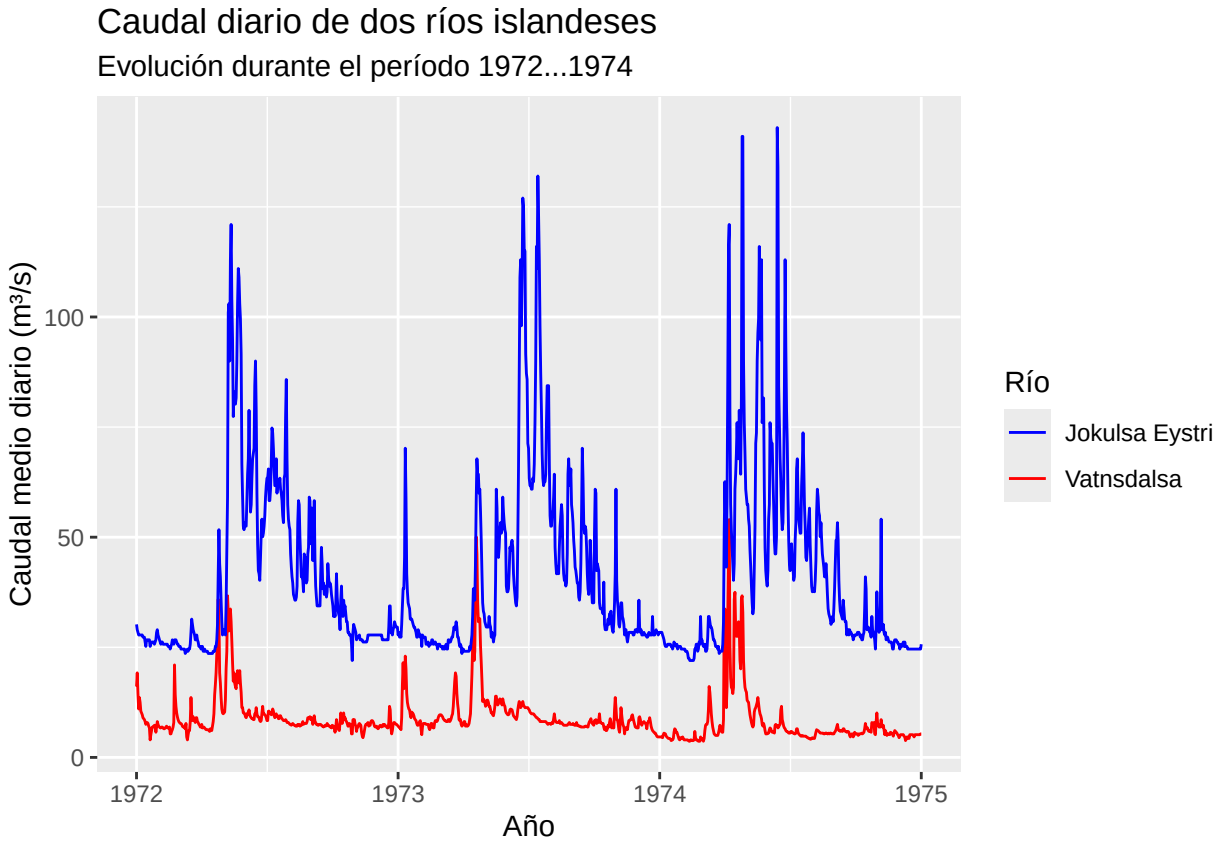
```
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <80>
```

```
## Warning in grid.Call(C_textBounds, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <93>
```

```
## Warning in grid.Call.graphics(C_text, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <e2>
```

```
## Warning in grid.Call.graphics(C_text, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <80>
```

```
## Warning in grid.Call.graphics(C_text, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <93>
```




```
ggsave(
  filename = "./results/Ejercicio6.pdf",
  plot = grafico_leyenda
)
```

```
## Saving 6.5 x 4.5 in image
```

```
## Warning in grid.Call(C_textBounds, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <e2>
```

```
## Warning in grid.Call(C_textBounds, as.graphicsAnnot(x$label), x$x, x$y, :
```

```
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <80>

## Warning in grid.Call(C_textBounds, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <93>

## Warning in grid.Call.graphics(C_text, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <e2>

## Warning in grid.Call.graphics(C_text, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <80>

## Warning in grid.Call.graphics(C_text, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <93>

## Warning in grid.Call.graphics(C_text, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <e2>

## Warning in grid.Call.graphics(C_text, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <80>

## Warning in grid.Call.graphics(C_text, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Evolución durante el período 1972-1974' in 'mbcsToSbcs':
## dot substituted for <93>
```

1.6. Ejercicio 7

```r
load("data/weatherAUS_distributions.RData")

str(ds)
```

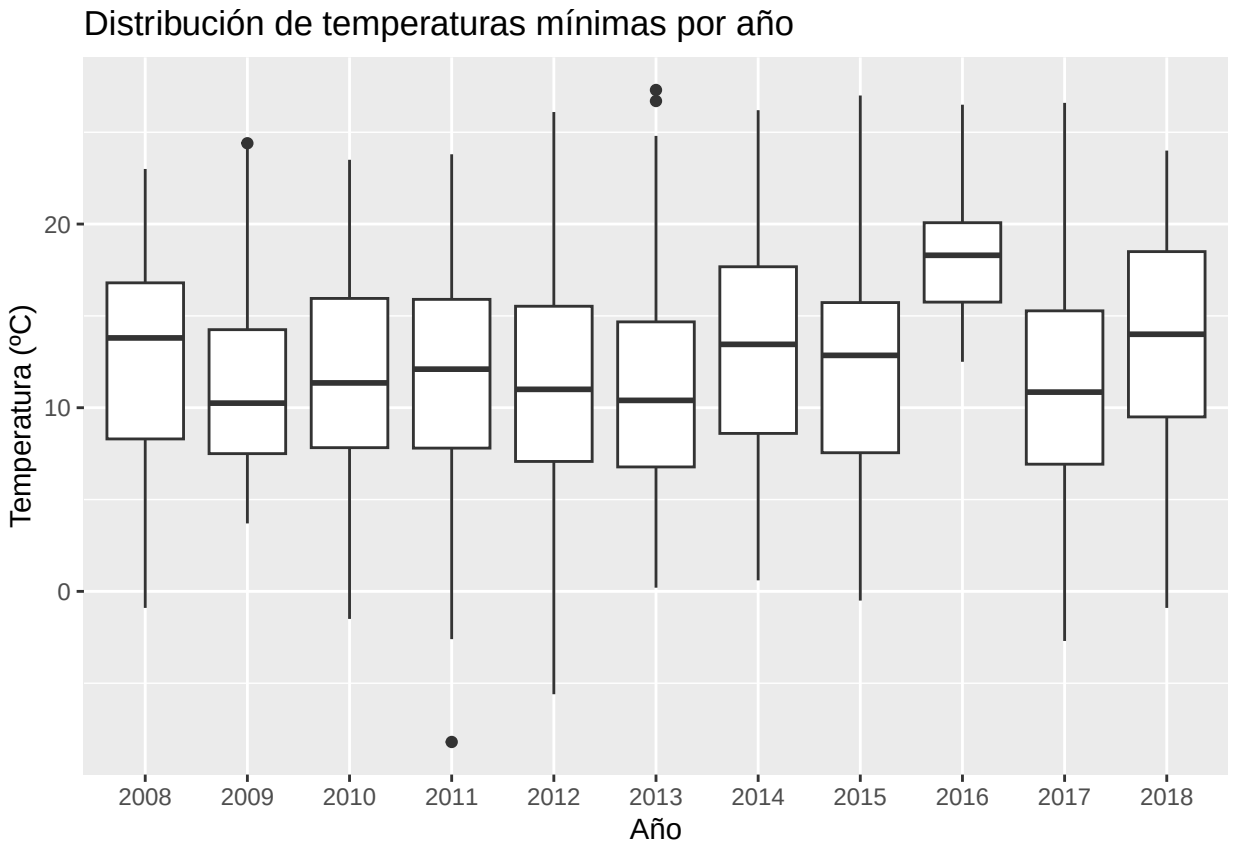
```
## 'data.frame':    863 obs. of  24 variables:
##  $ Year         : Factor w/ 11 levels "2008","2009",..: 2 7 3 6 5 10 10 7 7 2 ...
##  $ Location     : chr  "Richmond" "Albury" "Launceston" "Sale" ...
##  $ MinTemp      : num  14.2 13.9 0.4 0.2 10.2 9 8.6 24 12.4 24.4 ...
##  $ MaxTemp      : num  29.8 27.7 13.1 15.1 20.7 17.2 23.9 34.2 18 31.9 ...
##  $ Rainfall     : num  0.2 1.4 0 0.2 0 1 0 0 2 18.4 ...
##  $ Evaporation  : chr  "12.2" NA NA "1.2" ...
##  $ Sunshine     : chr  NA NA NA "7.3" ...
##  $ WindGustDir  : chr  "NE" "W" "S" "NW" ...
##  $ WindGustSpeed: int  28 37 19 17 NA 44 63 41 NA 31 ...
##  $ WindDir9am   : chr  NA "ENE" NA "WNW" ...
##  $ WindDir3pm   : chr  "E" "NW" "SSE" "NNW" ...
##  $ WindSpeed9am : int  0 6 0 9 6 22 13 15 6 11 ...
##  $ WindSpeed3pm : int  11 22 4 7 13 30 39 15 35 17 ...
##  $ Humidity9am  : int  92 74 98 93 64 71 62 71 84 83 ...
##  $ Humidity3pm  : int  36 42 57 57 40 63 22 56 61 68 ...
##  $ Pressure9am  : num  1017 1008 1028 1024 1025 ...
##  $ Pressure3pm  : num  1014 1007 1026 1021 1020 ...
##  $ Cloud9am     : int  NA NA NA 2 5 3 2 6 7 6 ...
##  $ Cloud3pm     : int  NA 5 NA 3 7 8 1 3 3 6 ...
```

```
##  $ Temp9am      : num  18.3 20.9 4.3 3.7 13 12.8 15.4 29.7 15.3 27.9 ...
##  $ Temp3pm      : num  29.5 26.4 11.9 14.3 18.7 14.6 23.5 32.1 17.5 30.9 ...
##  $ RainToday    : chr  "No" "Yes" "No" "No" ...
##  $ RISK_MM      : num  0 0 0.4 0 0 0.2 0 0 1.6 24.2 ...
##  $ RainTomorrow : chr  "No" "No" "No" "No" ...
##  - attr(*, "spec")=
##   .. cols(
##   ..   Date = col_date(format = ""),
##   ..   Location = col_character(),
##   ..   MinTemp = col_double(),
##   ..   MaxTemp = col_double(),
##   ..   Rainfall = col_double(),
##   ..   Evaporation = col_character(),
##   ..   Sunshine = col_character(),
##   ..   WindGustDir = col_character(),
##   ..   WindGustSpeed = col_integer(),
##   ..   WindDir9am = col_character(),
##   ..   WindDir3pm = col_character(),
##   ..   WindSpeed9am = col_integer(),
##   ..   WindSpeed3pm = col_integer(),
##   ..   Humidity9am = col_integer(),
##   ..   Humidity3pm = col_integer(),
##   ..   Pressure9am = col_double(),
##   ..   Pressure3pm = col_double(),
##   ..   Cloud9am = col_integer(),
##   ..   Cloud3pm = col_integer(),
##   ..   Temp9am = col_double(),
##   ..   Temp3pm = col_double(),
##   ..   RainToday = col_character(),
##   ..   RISK_MM = col_double(),
##   ..   RainTomorrow = col_character()
##   .. )
```

El dataset contiene 863 observaciones meteorológicas de distintas localidades australianas y 24 variables, como temperaturas, precipitaciones, viento, humedad y presión, con algunos valores ausentes (`NA`).
La variable `Year` agrupa los registros en 11 años y permite comparar las distribuciones de `MinTemp` y `MaxTemp` por año.

```r
# Boxplots de las temperaturas mínimas por año.
grafico_boxplot <- ggplot(ds, aes(x = Year, y = MinTemp)) +
  geom_boxplot() +
  labs(
    title = "Distribución de temperaturas mínimas por año",
    x = "Año",
    y = "Temperatura (ºC)"
  )

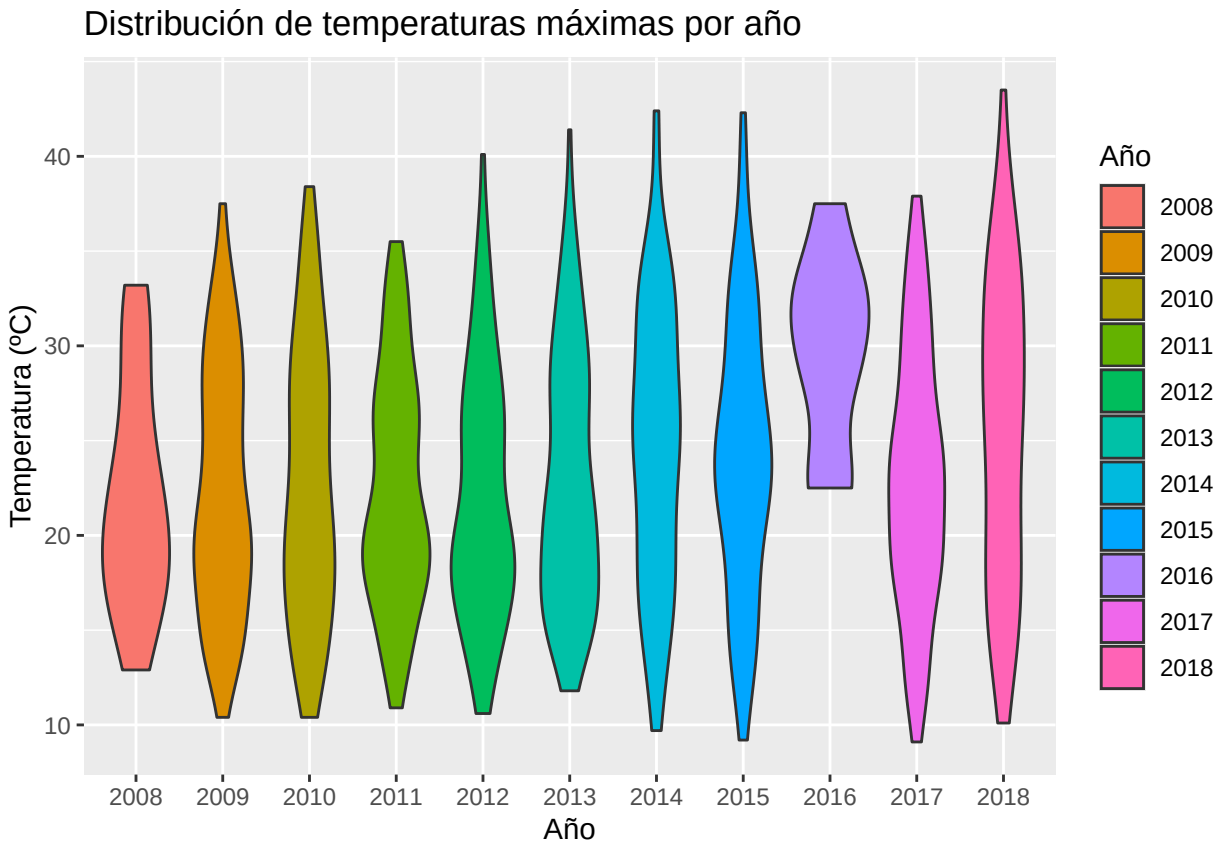
grafico_boxplot
```



Las temperaturas mínimas presentan medianas entre 10 y 14 °C en la mayoría de los años; destaca 2016, con una mediana cercana a 18 °C y menor dispersión.
Se observan valores atípicos en 2009, 2011 y 2013, sin una tendencia creciente o decreciente clara en el conjunto del período.

```
# Violines de las temperaturas máximas, coloreados por año.
grafico_violin <- ggplot(
  ds,
  aes(x = Year, y = MaxTemp, fill = Year)
) +
  geom_violin() +
  labs(
    title = "Distribución de temperaturas máximas por año",
    x = "Año",
    y = "Temperatura (ºC)",
    fill = "Año"
  )

grafico_violin
```

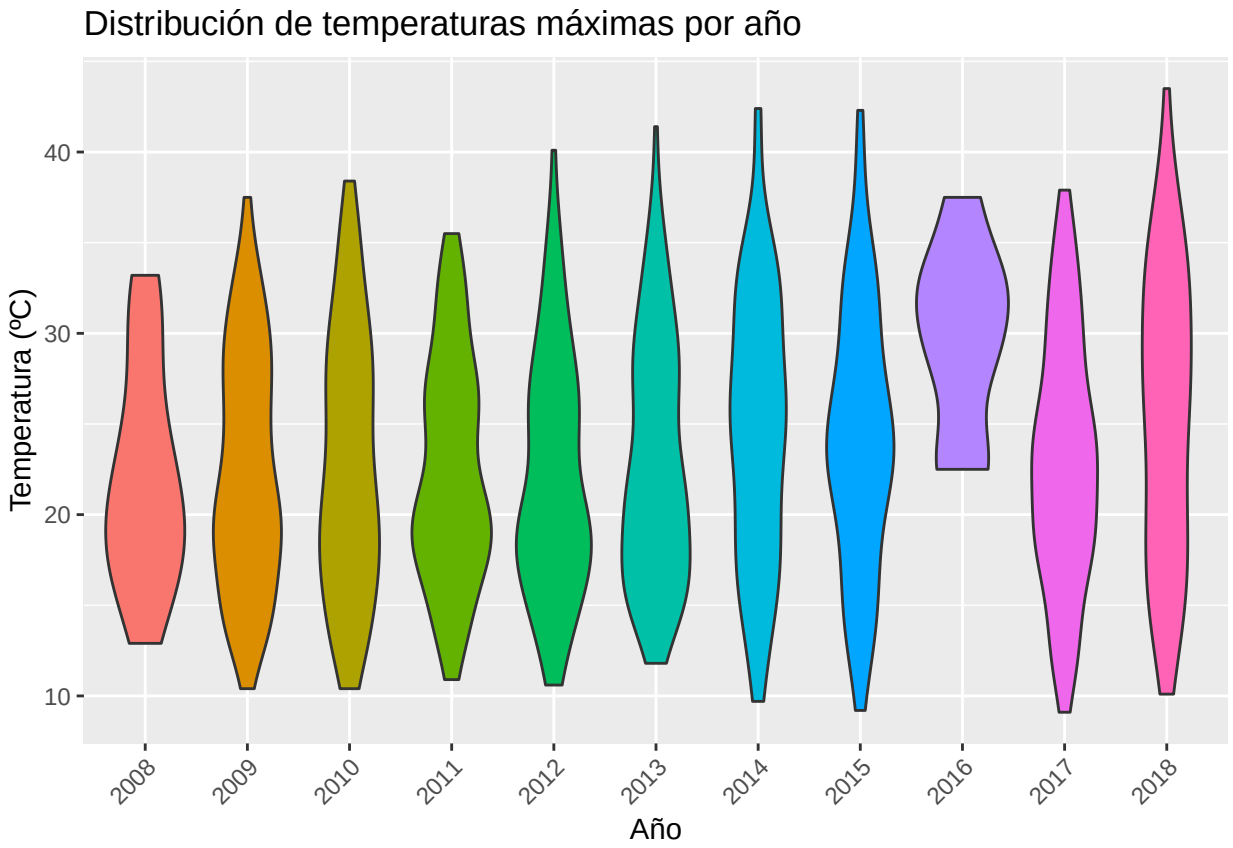


Los violines muestran dónde se concentran las temperaturas máximas: destaca 2016, con valores elevados y menor dispersión y 2008 ccon valores mas bajos y sin colas tan largas. Frente al boxplot anterior, muestran la densidad de la distribución, sin señalar medianas ni valores atípicos.

```
#Busco informacion sobre como inclinar el texto de x
#help(theme)
```

```
grafico_final <- grafico_violin +
  theme(
    legend.position = "none",
    axis.text.x = element_text(angle = 45, hjust = 1)
  )

grafico_final
```



En este caso que solo diferenciamos por colores los años eliminar la leyenda quita informacion redundante y hace mas limpia la grafica.

```
ggsave(
  filename = "./results/Ejercicio7.pdf",
  plot = grafico_final
)
```

```
## Saving 6.5 x 4.5 in image
```

1.7. Ejercicio 8

```
download.file(
  url = "https://assets.datacamp.com/blog_assets/chol.txt",
  destfile = "data/chol.txt",
  mode = "wb"
)

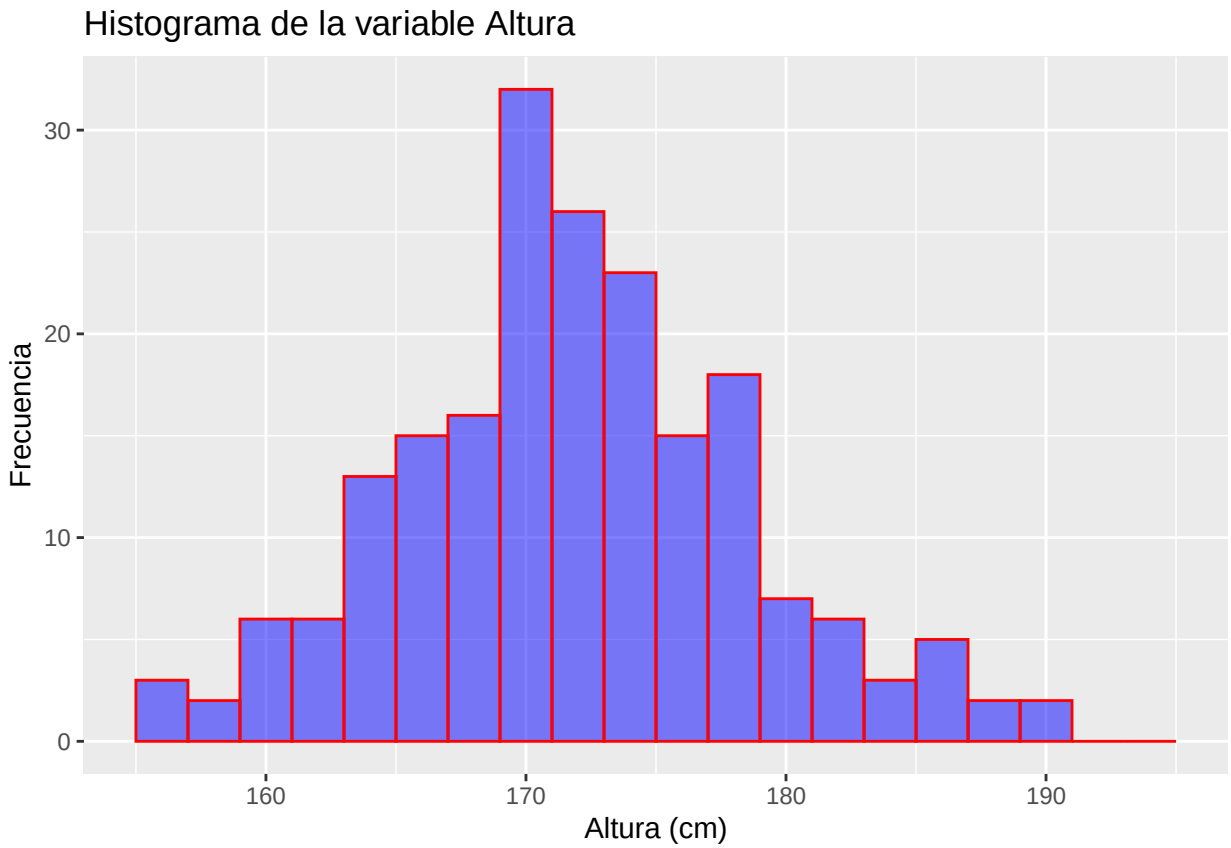
datos <- read.table("data/chol.txt", header = TRUE)
str(datos)
```

```
## 'data.frame':    200 obs. of  7 variables:
##  $ AGE   : int  20 53 44 37 26 41 39 28 33 39 ...
##  $ HEIGHT: int  176 167 170 173 170 165 174 171 180 166 ...
##  $ WEIGHT: int  77 56 80 89 71 62 75 68 100 74 ...
##  $ CHOL  : int  195 250 304 178 206 284 232 152 209 150 ...
##  $ SMOKE : chr  "nonsmo" "sigare" "sigare" "nonsmo" ...
##  $ BLOOD : chr  "b" "o" "a" "o" ...
##  $ MORT  : chr  "alive" "dead" "dead" "alive" ...
```

Se descarga el fichero `chol.txt` y se carga en un dataframe con 200 observaciones y 7 columnas: edad (`AGE`), altura (`HEIGHT`), peso (`WEIGHT`), colesterol (`CHOL`), hábito de fumar (`SMOKE`), grupo sanguíneo (`BLOOD`) y estado vital (`MORT`: vivo o fallecido).

```
# Histograma con barras azules, transparencia del 50% y borde rojo.
grafico1 <- ggplot(datos, aes(x = HEIGHT)) +
  geom_histogram(
    breaks = seq(155, 195, length.out = 21),
    fill = "blue",
    alpha = 0.5,
    color = "red"
  ) +
  labs(
    title = "Histograma de la variable Altura",
    x = "Altura (cm)",
    y = "Frecuencia"
  ) +
  coord_cartesian(xlim = c(155, 195))

grafico1
```

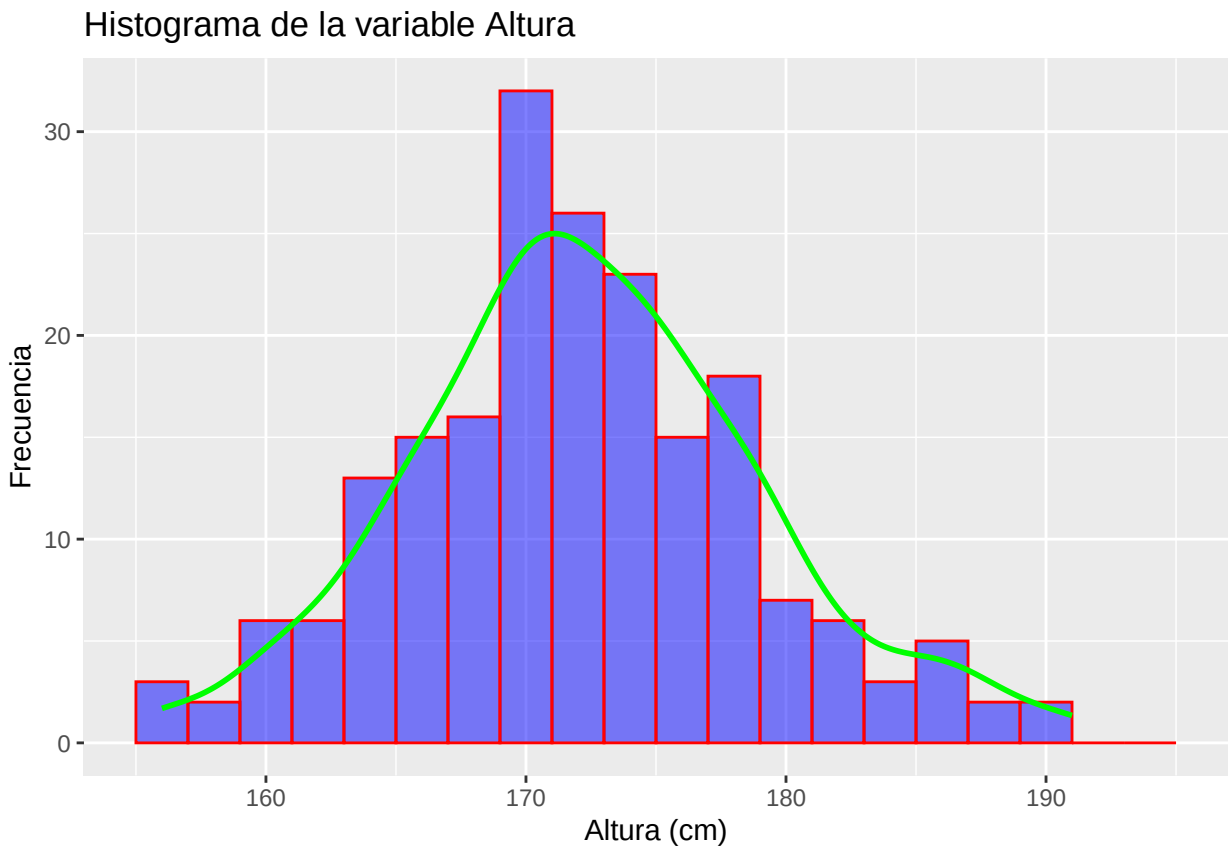


El histograma presenta barras azules con una transparencia del 50 % y contorno rojo, distribuidas en 20 intervalos entre 155 y 195 cm. La mayor concentración de alturas se encuentra entre 165 y 180 cm, con el intervalo más frecuente alrededor de 170 cm. La distribución es aproximadamente unimodal, con pocas observaciones en los extremos.

```
grafico2 <- grafico1 +
  geom_density(
```

```
    aes(y = after_stat(count*2)),
    color = "green",
    linewidth = 1
  )

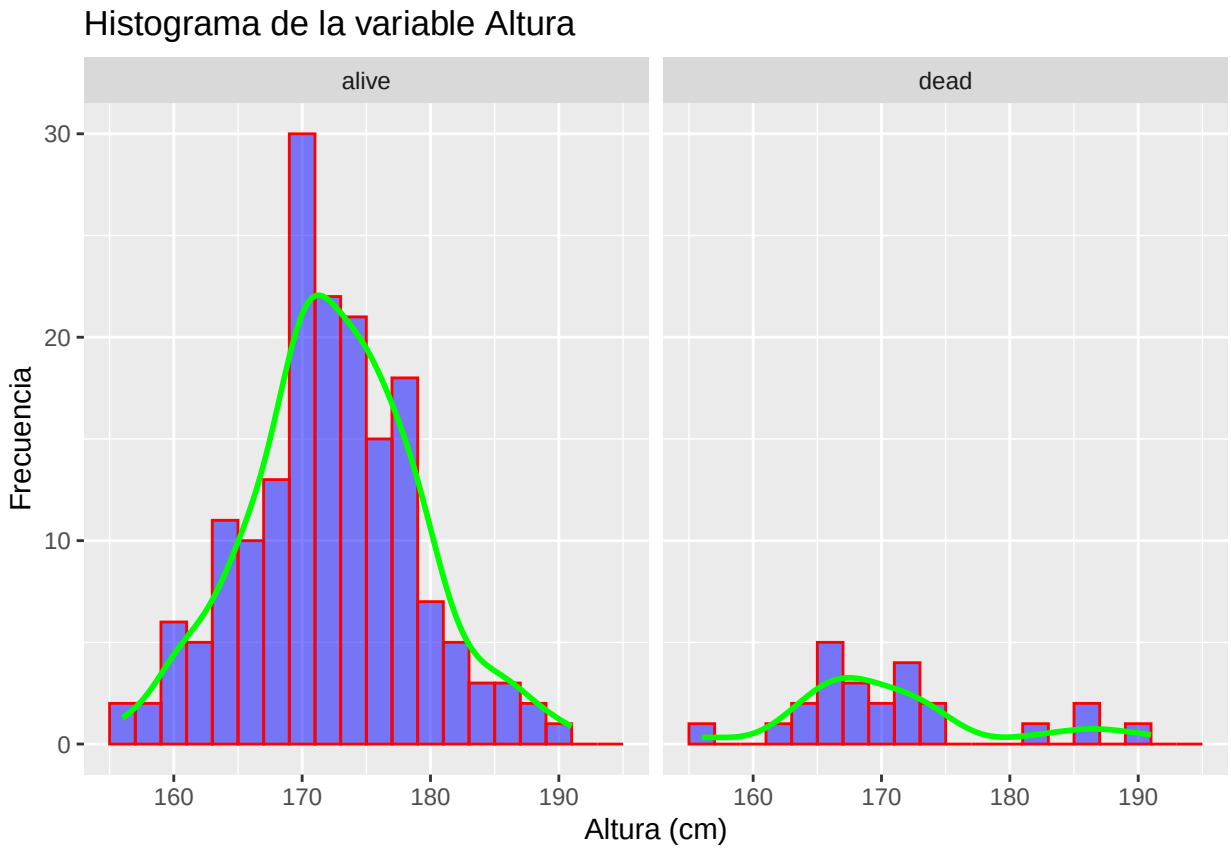
grafico2
```



Uso `count * 2` porque cada barra abarca 2 cm,`geom_density()` estima una curva de densidad; su variable calculada `count` equivale a **densidad × número de observaciones**. Al multiplicarla por la anchura del intervalo, la curva queda en la misma escala de frecuencias que las barras. En el gráfico, la curva verde muestra de forma suavizada la distribución de las alturas: la mayor concentración está alrededor de **170–175 cm**, y la frecuencia disminuye hacia ambos extremos.

```
grafico_final <- grafico2 +
  facet_grid(. ~ MORT )

grafico_final
```



El grupo `alive` concentra la mayoría de las observaciones, con alturas principalmente entre 165 y 180 cm y un máximo alrededor de 170 cm como lo que hemos observado en la grafica anterior.
El grupo `dead` tiene menos registros y una distribución más irregular; las curvas verdes suavizan ambas distribuciones, pero las frecuencias dependen del tamaño de cada grupo.

```
ggsave(
  filename = "./results/Ejercicio8.pdf",
  plot = grafico_final
)
```

```
## Saving 6.5 x 4.5 in image
```